

强化学习

目 录

| | | | | | |
|-------|----------------|----|--------|---------------------|----|
| 1 | 导论 | 5 | 6.2 | n-Sarsa | 24 |
| 2 | 马尔可夫决策过程与贝尔曼方程 | 6 | 6.3 | n-树回溯 | 26 |
| 2.1 | 马尔可夫决策过程 | 6 | 6.4 | n-Q(σ) | 28 |
| 2.1.1 | 要素 | 6 | 7 | 表格型方法总结对比 | 29 |
| 2.1.2 | 状态、动作与收益 | 7 | 8 | 值函数近似 | 31 |
| 2.1.3 | 策略 | 8 | 8.1 | 函数近似 | 31 |
| 2.1.4 | 回报与折扣 | 9 | 8.2 | 随机梯度下降 | 32 |
| 2.1.5 | 值函数 | 10 | 8.3 | DQN | 33 |
| 2.1.6 | 构建要点 | 11 | 9 | 策略梯度 | 35 |
| 2.2 | 贝尔曼方程 | 11 | 9.1 | 概念 | 35 |
| 2.2.1 | 贝尔曼方程 | 11 | 9.2 | REINFORCE | 36 |
| 2.2.2 | 贝尔曼最优方程 | 11 | 10 | Actor-Critic方法 | 37 |
| 3 | 动态规划 | 12 | 10.1 | 概念 | 37 |
| 3.1 | 策略迭代 | 13 | 10.2 | 优势Actor-Critic方法 | 37 |
| 3.2 | 值迭代 | 14 | 10.2.1 | 基线 | 37 |
| 3.3 | 对比与补充 | 15 | 10.3 | 离轨Actor-Critic方法 | 39 |
| 4 | 蒙特卡洛 | 15 | 10.4 | 确定性策略Actor-Critic方法 | 39 |
| 4.1 | 概念 | 15 | 11 | 策略搜索方法总结对比 | 40 |
| 4.2 | on-policy | 16 | 12 | 附录 | 40 |
| 4.3 | off-policy | 17 | 12.1 | 历史 | 40 |
| 4.4 | 对比 | 18 | 12.2 | 贝尔曼最优方程求解 | 41 |
| 5 | 时序差分 | 18 | 12.3 | 表格型方法 | 42 |
| 5.1 | TD(0) | 19 | 12.3.1 | DP补充 | 42 |
| 5.2 | Sarsa | 20 | 12.3.2 | MC补充 | 42 |
| 5.3 | Q-learning | 21 | 12.3.3 | TD补充 | 42 |
| 5.4 | 对比与补充 | 22 | 12.3.4 | 模型和规划 | 43 |
| 6 | n步自举法 | 23 | 12.3.5 | Dyna-Q | 43 |
| 6.1 | n-TD | 23 | 12.3.6 | 改进方法 | 44 |
| | | | 12.4 | 核函数近似 | 45 |
| | | | 12.5 | 数学基础 | 45 |

图 片

| | | | | | |
|-----|------------------------------|----|------|--------------------------|----|
| 图 1 | 马尔可夫决策过程 | 7 | 图 7 | TD回溯图 | 19 |
| 图 2 | 回收机器人状态转移 | 8 | 图 8 | Sarsa回溯图 | 20 |
| 图 3 | DP回溯图 | 10 | 图 9 | 期望Sarsa回溯图 | 21 |
| 图 4 | DP回溯图的两种形式（最优） | 12 | 图 10 | Q-learning回溯图 | 21 |
| 图 5 | DP回溯图 | 12 | 图 11 | 双Q-learning回溯图 | 22 |
| 图 6 | MC回溯图：显示一幕所有采样到的转移 | 16 | 图 12 | n-Sarsa回溯图 | 24 |
| | | | 图 13 | n-树回溯回溯图 | 27 |
| | | | 图 14 | Q(sigma)回溯图 | 28 |
| | | | 图 15 | 表格型方法对比 | 30 |
| | | | 图 16 | 表达式对比 | 30 |

表 格

| | | |
|-----|---------------------------------|----|
| 表 1 | DP对比 | 15 |
| 表 2 | MC对比 | 18 |
| 表 3 | 各算法中的 \bar{q}_t 表达式 | 31 |

算 法

| | | | | | |
|-------|--------------------------------------|----|-------|--------------------------------------|----|
| 算法 1 | 策略迭代 | 13 | 算法 11 | n-期望Sarsa-off-policy | 25 |
| 算法 2 | 值迭代 | 14 | 算法 12 | n-树回溯 | 27 |
| 算法 3 | MC-On-policy（first visit） | 16 | 算法 13 | n-Q(σ)-off-policy | 28 |
| 算法 4 | MC-Off-policy（every visit） | 17 | 算法 14 | 梯度蒙特卡洛 | 33 |
| 算法 5 | TD(0) | 19 | 算法 15 | 半梯度TD(o) | 33 |
| 算法 6 | Sarsa（on-policy-TD） | 20 | 算法 16 | DQN | 34 |
| 算法 7 | Q-learning（off-policy-TD） | 21 | 算法 17 | REINFORCE | 36 |
| 算法 8 | 双Q-learning | 22 | 算法 18 | QAC | 37 |
| 算法 9 | n-TD | 23 | 算法 19 | A2C | 38 |
| 算法 10 | n-Sarsa | 24 | 算法 20 | 重要性采样离轨Actor-Critic | 39 |
| | | | 算法 21 | 确定性策略离轨Actor-Critic | 39 |
| | | | 算法 22 | Dyna-Q | 43 |
| | | | 算法 23 | 确定性环境下的优先遍历 | 44 |

要 点

| | | | | | |
|------|--------------------------------|---|------|--------------------|----|
| 要点 1 | 马尔可夫决策过程及其元素 | 6 | 要点 4 | 增量式更新 | 9 |
| 要点 2 | 马尔可夫性 | 7 | 要点 5 | 分幕与回报 | 9 |
| 要点 3 | ϵ -greedy策略 | 8 | 要点 6 | 值函数与回溯算法 | 10 |
| | | | 要点 7 | 贝尔曼方程 | 11 |
| | | | 要点 8 | 策略迭代 | 13 |

| | | | | | |
|-------|--------------------------------------|----|-------|-------------------------------|----|
| 要点 9 | 值迭代 | 14 | 要点 21 | n-树回溯 | 26 |
| 要点 10 | 蒙特卡洛 | 15 | 要点 22 | n-Q(σ) | 28 |
| 要点 11 | on-policy | 16 | 要点 23 | 表格型方法总结对比 | 29 |
| 要点 12 | off-policy | 17 | 要点 24 | 随机梯度下降 | 32 |
| 要点 13 | 重要度采样 | 17 | 要点 25 | DQN及其关键技术 | 33 |
| 要点 14 | 时序差分 (TD(0)) | 19 | 要点 26 | 策略梯度 | 35 |
| 要点 15 | Sarsa (on-policy-TD) | 20 | 要点 27 | REINFORCE | 36 |
| 要点 16 | 期望Sarsa | 20 | 要点 28 | Actor-Critic方法 | 37 |
| 要点 17 | Q-learning (off-policy-TD) | 21 | 要点 29 | 优势Actor-Critic方法 | 37 |
| 要点 18 | 双Q-learning | 21 | 要点 30 | 基线 | 37 |
| 要点 19 | n-TD | 23 | 要点 31 | 离轨Actor-Critic方法 | 39 |
| 要点 20 | n-Sarsa | 24 | 要点 32 | 确定性策略Actor-Critic方法 | 39 |

1 导论

特征 智能体与环境交互（采样），在不断尝试中学习策略，使收益最大化。

- 试错探索：不会获知应采取的行动，通过尝试获得。
- 延迟收益：一个动作的收益可能无法短期体现，而是长期浮现。
- 环境不确定性：当前动作不但会影响当前收益，还会影响后续环境，进而影响后续收益。
- 影响未知性：无法预测动作的影响，需要与环境频繁交互。
- 试探（开拓动作空间）与开发/贪心（根据经验获得收益）折中。

优化方法对比

- 凸优化：状态空间较小。可线性规划。
- 最优控制：已知模型，解析回报函数。可动态规划，解HJB方程。
- 进化算法：控制策略简单。如遗传算法。
- 机器学习
 - 有监督学习：有标签数据，注重推断与泛化能力。
 - 无监督学习：无标签数据，寻找数据隐含结构。
- 强化学习：交互数据，优化策略以优化收益。

分类

1. 模型依赖性

- 有模型：学习模型，规划策略。
- 无模型：直接试错策略。

2. 策略更新方法

- 值函数：求解值函数重构策略。
- 直接策略搜索：策略梯度等方法，搜索策略空间。

- Actor-Critic方法：类似策略梯度，同时逼近值函数和策略。
3. 回报函数是否已知
 - 正向：从回报到策略。
 - 逆向：从专家示例到回报。
 4. 任务体量：分层强化学习、元强化学习、多智能体强化学习、迁移学习等
 5. 框架
 - 间接强化学习：充分利用有限经验，获得更好策略，减少与环境的交互。
 - 直接强化学习：不受模型设计偏差影响。

发展

值函数→直接策略搜索（策略梯度等）→深度强化学习。详见12.1。

发展方向：与深度学习结合，与专业知识结合，理论分析型增强，与认知科学结合，体量增大，与贝叶斯结合。

2 马尔可夫决策过程与贝尔曼方程

2.1 马尔可夫决策过程（Markov decision process, MDP）

2.1.1 要素 ¹

- 状态（state, S ）：强化学习依赖的概念。
- 动作（action, A ）：智能体做出的选择。
- 奖励/收益（reward, R ）：短期学习目标，环境给予智能体的信号。
- 策略（policy, π ）：在特定状态下，动作集的分布 $\pi(a|s) = p[A_t = a|S_t = s]$ 。
- 回报（return, G ）：长期收益累计，可能含有折扣，需综合评估。
- 折扣因子（ $\gamma \in [0, 1]$ ）。

- 值函数 (value function, V): 对 s 预估的期望回报。
- 行为/动作值函数 (Q): 对 (s, a) 预估的期望回报。
- 环境模型 (P): 模拟环境的反应, 可以是确定性转移, 也可以是随机性转移。
- 大写字母表示空间, 小写字母表示个体, 上标*表示最优。




图 1: 马尔可夫决策过程

2.1.2 状态、动作与收益

序贯交互轨迹 (TRAJECTORY) $\tau = s_0, a_0, r_1, s_1, a_1, r_2, \dots$

随机变量 s', r 服从离散概率分布 $p(s', r|s, a) \doteq \Pr\{S_t = s', R_t = r | S_{t-1} = s, A_{t-1} = a\}$

$$\sum_{s' \in S} \sum_{r \in R} p(s', r|s, a) = 1$$

。

马尔可夫性 ² 即“无记忆性”, 未来状态仅依赖当前状态, 而独立于过去状态。

$$P(S_{t+1}|S_t, S_{t-1}, \dots, S_0) = P(S_{t+1}|S_t)$$

状态转移与期望收益

由 s 和 a 转移到 s' 的概率, 包括 s' 下各可能收益情况:

$$p(s'|s, a) \doteq \Pr\{S_t = s' | S_{t-1} = s, A_{t-1} = a\} = \sum_{r \in R} p(s', r|s, a)$$

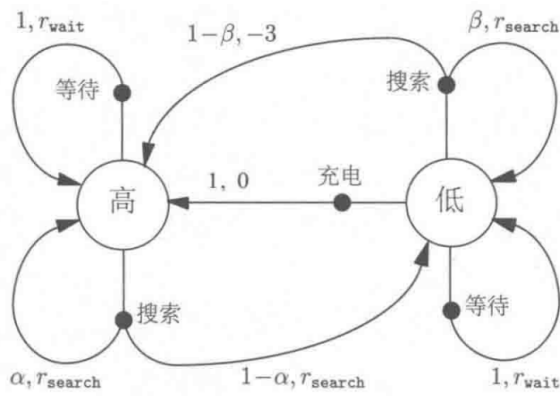
若不指定 a , 由 s 转移到 s' 的概率为:

$$p(s'|s) = \sum_{a \in A} [p(s'|s, a)p(a|s)]$$

有无 s' 的两种期望收益：

$$r(s, a) \doteq E[R_t | S_{t-1} = s, A_{t-1} = a] = \sum_{r \in R} r \sum_{s' \in S} p(s', r | s, a)$$

$$r(s, a, s') \doteq E[R_t | S_{t-1} = s, A_{t-1} = a, S_t = s'] = \sum_{r \in R} r \frac{p(s', r | s, a)}{p(s' | s, a)}$$



(a) 状态转移图（节点不能重复）

| s | a | s' | $p(s' s, a)$ | $r(s, a, s')$ |
|------|----------|------|----------------|---------------------|
| high | search | high | α | r_{search} |
| high | search | low | $1 - \alpha$ | r_{search} |
| low | search | high | $1 - \beta$ | -3 |
| low | search | low | β | r_{search} |
| high | wait | high | 1 | r_{wait} |
| high | wait | low | 0 | r_{wait} |
| low | wait | high | 0 | r_{wait} |
| low | wait | low | 1 | r_{wait} |
| low | recharge | high | 1 | 0 |
| low | recharge | low | 0 | 0 |

(b) 状态转移表

图 2: 回收机器人状态转移

2.1.3 策略

贪婪策略 $\pi(a|s) = \arg\max_a q(a)$ 。

探索-利用平衡策略

- ϵ -greedy策略³：靠近贪心策略，但所有动作概率不为零。实际使用时需注意多最优情况。

$$a = \begin{cases} \arg\max_a q(a) & , p = 1 - \epsilon \\ \text{random}(a) & , p = \epsilon \end{cases} \Rightarrow \pi(a|s) = \begin{cases} 1 - \epsilon + \frac{\epsilon}{|A|} & , a = \arg\max_a q(a) \\ \frac{\epsilon}{|A|} & , \text{otherwise} \end{cases}$$

- UCB（Upper Confidence Bound）策略：可以自适应平衡探索与利用。

$$\pi(a|s) = Q(a) + c \sqrt{\frac{\ln N}{n(a)}}$$

其中， c 控制探索强度， N 是当前轮数， $n(a)$ 是 a 被选次数。

- 玻尔兹曼分布 (Boltzmann): 可以动态调整探索强度。

$$\pi(a|s) = \frac{e^{Q(a)/\tau}}{\sum_{a'} e^{Q(a')/\tau}}$$

其中 τ 是温度参数, 控制随机程度, 趋于0时贪心, 趋于 ∞ 时随机。

- 高斯策略:

$$\pi = \mu + \epsilon, \epsilon \sim N(0, \sigma^2)$$

增量式更新 4 将轮次更新转化为递推关系, 减少空间复杂度, 如运行均值:

$$Q_{n+1} = \frac{1}{n} \sum_{i=1}^n R_i = Q_n + \frac{1}{n}(R_n - Q_n)$$

2.1.4 回报与折扣 5

- 幕 (episode): 一次交互序列, 幕间没有联系。
- 终止时刻T: 划分非终结状态集S和所有状态集 S^+ 。
- 分幕式任务 (episodic tasks): 有终止状态, 可分幕。

$$G_t = R_{t+1} + R_{t+2} + \cdots + R_T = \sum_{k=t+1}^T R_k$$

- 持续性任务 (continuing tasks): 没有终止状态, 持续进行, 不能自然分幕。

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \leq \frac{1}{1-\gamma} \max R_t$$

其中 γ 越大代表长期收益越重要。

- 统一表示: 有限项终止后, 状态持续转移回自己, 相当于无限项。

$$G_t \doteq \sum_{k=t+1}^T \gamma^{k-t-1} R_k$$

2.1.5 值函数 ⁶

值函数

$$\begin{aligned}
v_{\pi}(s) &\doteq E_{\pi}[G_t | S_t = s] = E_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s\right], s \in S \\
&= E_{\pi}\left[\underbrace{R_{t+1}}_{\text{即时奖励}} + \gamma \underbrace{G_{t+1}}_{\text{未来奖励}} | S_t = s\right] (\text{后继递推关系}) \\
&= \sum_{a \in A} \pi(a|s) \left[\sum_{r \in R} p(r|s, a)r + \gamma \sum_{s' \in S} p(s'|s, a)v_{\pi}(s') \right] (\text{分项全概率展开}) \\
&= \sum_{a \in A} \pi(a|s) \underbrace{\sum_{s' \in S, r \in R} p(s', r|s, a)[r + \gamma v_{\pi}(s')]}_{\text{贝尔曼方程}} (\text{值函数递推关系})
\end{aligned}$$

行为值函数

$$\begin{aligned}
q_{\pi}(s, a) &\doteq E_{\pi}[G_t | S_t = s, A_t = a] = E_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s, A_t = a\right], s \in S \\
&= \sum_{r \in R} p(r|s, a)r + \gamma \sum_{s' \in S} P(s'|s, a) \underbrace{\sum_{a' \in A} \pi(a'|s') q_{\pi}(s'|a')}_{v_{\pi}(s')} (\text{状态值函数递推关系})
\end{aligned}$$

回溯算法 s' 的价值信息回传给 s 。




图 3: DP回溯图（节点可以重复）

最优值函数与最优策略

- $\forall s \in S, q_{\pi}(s, \pi'(s)) = v_{\pi'}(s) \geq v_{\pi}(s)$, 则称 π' 优于或等于 π 。

- $v_\pi(s)$ 定义了 π 的偏序关系, π^* 存在且可能不唯一, 它们共享:

$$v^*(s) \doteq \max_{\pi} v_{\pi}(s) \quad q^*(s, a) \doteq \max_{\pi} q_{\pi}(s, a)$$

2.1.6 构建要点

- 确定 s, a, r (不含先验知识, 不为达到子目标而舍弃最终目标)。
- 奖励与惩罚是相对的, 可以全奖励或全惩罚。
- 同一问题可能有多层次MDP。
- 利用先验知识, 人为排除愚蠢动作。

2.2 贝尔曼方程 7

2.2.1 贝尔曼方程

$$\begin{aligned} \underline{v_{\pi}(s)} &= \sum_{a \in A} \pi(a|s) \sum_{s' \in S, r \in R} P(s', r|s, a) [r + \gamma \underline{v_{\pi}(s')}] \\ &= \underbrace{\sum_{a \in A} \pi(a|s) \sum_{r \in R} P(r|s, a)}_{r_{\pi}(s)} + \gamma \sum_{s' \in S} \underbrace{\left[\sum_{a \in A} \pi(a|s) P(s'|s, a) \right]}_{p_{\pi}(s'|s)} \underline{v_{\pi}(s')} \end{aligned}$$

2.2.2 贝尔曼最优方程

方程组中方程数为 $|S|$, 如 P 已知, 并具有马尔可夫性, 则可求解。但一般难以满足, 且计算资源有限, 求近似解。

形式

- $s \rightarrow a^*$:

$$\begin{aligned} v^*(s) &= \max_{a \in A} q_{\pi^*}(s, a) (\text{凸组合最优}) \\ &= \max_{\pi} \sum_{s \in S} \pi(a|s) q(s, a) (\text{元素}) \\ &= \max_{\pi} (r_{\pi} + \gamma P_{\pi} v) (\text{矩阵}) \end{aligned}$$

- $(s, a) \rightarrow (s, a)_{\text{next}}^*$:

$$\begin{aligned} q^*(s, a) &= E[R_{t+1} + \gamma \max_{a'} q^*(S_{t+1}, a') | S_t = s, A_t = a] \\ &= \sum_{s' \in S, r \in R} p(s', r | s, a) [r + \gamma \max_{a'} q^*(s', a')] \end{aligned}$$




图 4: DP回溯图的两两种形式（最优）

求解 伸缩映射性，见12.2。

贪婪最优策略 π^* 中， $v(s) = E[r(a^*|s)]$ ，可使用贪心策略求取（证明：凸组合最大值为最大一项）。

3 动态规划（DYNAMIC PROGRAMMING，DP）：期望更新

使用值函数结构化组织最优策略搜索，将贝尔曼方程转化成近似逼近理想值函数的递归更新公式，即将多阶段决策问题转化为多个单阶段决策问题。




图 5: DP回溯图：显示一步的所有转移

3.1 策略迭代 ⁸

$$\pi_0 \xrightarrow{\text{PE}} v_{\pi_0} \xrightarrow{\text{PI}} \pi_1 \xrightarrow{\text{PE}} v_{\pi_1} \xrightarrow{\text{PI}} \pi_2 \xrightarrow{\text{PE}} v_{\pi_2} \xrightarrow{\text{PI}} \dots$$

反复进行PE和PI，得到改进的 v_{π} 估计和 π ，最后收敛到最优。

- 策略评估 (PE):

- 直接求解: $v_{\pi_k} = (I - \gamma P_{\pi_k})^{-1} r_{\pi_k}$ 。

- 迭代求解:

$$v_{\pi_k}^{(j+1)} = r_{\pi_k} + \gamma P_{\pi_k} v_{\pi_k}^{(j)} = \underbrace{\sum_{a \in A} \pi(a|s) [r(a|s) + \gamma \sum_{s' \in S} P(s'|s, a) v_{\pi_k}^{(j)}(s')]}_{\text{期望更新: 基于后继可能状态的期望值}}, j = 0, 1, 2, \dots$$

- 截断策略评估: 不需要完全收敛。

- 策略改进 (PI):

- 理论: $v_{\pi}(s) \leq q_{\pi}[s, \pi'(s)]$ 则 π' 不次于 π

$$\begin{aligned} v_{\pi}(s) &\leq q_{\pi}[s, \pi'(s)] \\ &= E_{\pi'}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) | S_t = s, A_t = \pi'(s)] \\ &\leq E_{\pi'}[R_{t+1} + \gamma q_{\pi}[S_{t+1}, \pi'(S_{t+1})] | S_t = s] \\ &\leq E_{\pi'}[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots | S_t = s] \\ &= v_{\pi'}(s) \end{aligned}$$

- 贪心策略: $\pi_{k+1} = \operatorname{argmax}_{\pi} (r_{\pi} + \gamma P_{\pi} v_{\pi_k})$

算法 1: 策略迭代

- 1: 参数: 估计精度阈值 $\theta > 0$
- 2: 初始化: $\forall s \in S$, 任意初始化 $v(s) \in \mathbb{R}, \pi(s)$
- 3: 循环
- 4: 循环 ▷ 策略评估
- 5: $\Delta \leftarrow 0$
- 6: 对于 $\forall s \in S$ 执行
- 7: $v_{\pi_k}^{(j+1)}(s) \leftarrow \sum_{a \in A} \pi_k(a|s) [\sum_{r \in \mathbb{R}} p(r|s, a)r + \gamma \sum_{s' \in S} p(s'|s, a) v_{\pi_k}^{(j)}(s')]$
- 8: $\Delta \leftarrow \max(\Delta, |v - v_{\pi_k}^{(j+1)}(s)|)$

算法 1: 策略迭代

```

9:   直到  $\Delta < \theta$ 
10:  策略稳定  $\leftarrow \text{true}$ 
11:  对于  $\forall s \in S$  执行
12:       $a_{\text{old}} \leftarrow \pi(s)$ 
13:      对于  $\forall a \in A(s)$  执行
14:           $q_{\pi_k}(s, a) \leftarrow \sum_{r \in R} p(r|s, a)r + \gamma \sum_{s' \in S} p(s'|s, a)v_{\pi_k}(s')$ 
15:           $a_k^*(s) \leftarrow \arg\max_a q_{\pi_k}(s, a)$ , 并更新  $\pi(s)$ 
16:          如果  $a_{\text{old}} \neq a_k^*(s)$  那么
17:              策略稳定  $\leftarrow \text{false}$ 
18:  直到 策略稳定

```

▷ 策略改进

3.2 值迭代 ⁹

$$u_0 \xrightarrow{\text{PU}} \pi'_1 \xrightarrow{\text{VU}} u_1 \xrightarrow{\text{PU}} \pi'_2 \xrightarrow{\text{VU}} u_2 \xrightarrow{\text{PU}} \dots$$

结合极端PE和PI，只进行一次PE遍历，对每个状态更新一次。

$$v_{k+1} = \max_{\pi} r_{\pi} + \gamma P_{\pi} v_k, k = 1, 2, 3, \dots$$

- 策略更新 (PU): $\pi_{k+1} = \arg\max_{\pi} (r_{\pi} + \gamma P_{\pi} v_k)$, 贪婪选取。
- 价值更新 (VU): $v_{k+1} = r_{\pi_{k+1}} + \gamma P_{\pi_{k+1}} v_k = \max_{a \in A} q_k$ 。

算法 2: 值迭代

```

1: 参数: 估计精度阈值  $\theta > 0$ 
2: 初始化:  $\forall s \in S^+$ , 任意初始化  $v(s)$ ,  $v(\text{终止}) = 0$ 
3: 循环
4:    $\Delta \leftarrow 0$ 
5:   对于  $\forall s \in S$  执行
6:       对于  $\forall a \in A(s)$  执行
7:            $q_k(s, a) \leftarrow \sum_{r \in R} p(r|s, a)r + \gamma \sum_{s' \in S} p(s'|s, a)v_k(s')$ 
8:            $a_k^*(s) \leftarrow \arg\max_a q_k(s, a)$ 

```

▷ 贪婪策略

算法 2：值迭代

| | | |
|-----|--|-------------|
| 9: | 若 $a = a_k^*$ 且 $\pi_{k+1}(a s) = 0$, 则令 $\pi_{k+1}(a s) = 1$ | ▷ 策略更新 |
| 10: | $v_{k+1}(s) \leftarrow \max_a q_k(s, a)$ | ▷ 价值更新 |
| 11: | $\Delta \leftarrow \max(\Delta, v_{k+1} - v_k)$ | ▷ 一轮中反复更新精度 |
| 12: | 直到 $\Delta < \theta$ | |

3.3 对比与补充**表 1: DP对比**

| | 策略迭代 | 值迭代 |
|--------|--------------------|---------------|
| 维护内容 | 值函数+策略 | 值函数 |
| 收敛速度 | 较快 | 较慢 |
| 收敛性 | 依赖初始策略质量, 可能陷入局部最优 | 保证全局最优 |
| 适用策略空间 | 简单 | 复杂 |
| 计算成本 | 较低 | 较高 (迭代遍历所有动作) |

补充见[12.3.1](#)。

4 蒙特卡洛 (MONTE CARLO, MC): 采样更新

针对分幕式任务, 不需要P, 通过多幕采样数据获得经验代替值函数解决问题。

4.1 概念 10

核心需求 由于P的缺失, $v(s)$ 是不够的, 需要评估 $q(s, a)$ 。

估计 $q(s, a)$

- 访问 (visit): 给定的一幕中, 指定状态的一次出现。
- 首次访问 (first visit): $\hat{q}(s, a) = \frac{G_{11}(s, a) + G_{21}(s, a) + \dots}{N(s, a)}$ 。

- 每次访问 (every visit): $\hat{q}(s, a) = \frac{G_{11}(s, a) + G_{12}(s, a) + \dots + G_{21}(s, a) + \dots}{N(s, a)}$ 。

$N(s)$ 是 s 的访问次数, $N(s) \rightarrow \infty, \hat{q}(s, a) \rightarrow q_{\pi}(s, a)$ 。



图 6: MC回溯图: 显示一幕所有采样到的转移

幕长 靠近目标的状态比远离目标的状态更早具有非零值, 幕长应足够长, 无需无限长。

优势

- 不需要 P , 可从实际经历和模拟经历中学习。
- 对每个状态的估计是独立的, 可聚焦于状态子集, 无需考虑其他状态, 效率高。
- 无马尔可夫性时性能损失较小。

恒温策略: $\forall (s, a), \pi(a|s) > 0$

1. 试探性出发 (ES): 为采样部分无法正常获得的 (s, a) , 可设定所有 (s, a) 都有概率作为起始。满足充分探索的理论要求, 但实际中很难实现。
2. ϵ -greedy策略。

4.2 on-policy (同轨) 11

采样并改进相同策略。

算法 3: MC-On-policy (first visit)

- 1: 参数: $\epsilon > 0$
- 2: 初始化: $\forall s \in S, a \in A(s)$, 任意初始化 $q(s, a) \in \mathbb{R}$, 初始化Returns(s, a)为空列表, ϵ -greedy初始化 π
- 3: 循环
- 4: 根据 π 生成一幕序列 $S_0, A_0, R_1, S_1, A_1, R_2, \dots, S_{T-1}, A_{T-1}, R_T$
- 5: $G \leftarrow 0$
- 6: 对于 $t = T - 1, T - 2, \dots, 0$ 执行

算法 3: MC-On-policy (first visit)

```

7:       $G \leftarrow \gamma G + R_{t+1}$ 
8:      如果  $S_t$  在此幕中首次出现 那么
9:          将  $G$  加入  $\text{Returns}(S_t, A_t)$ 
10:      $q(S_t, A_t) \leftarrow \text{average}[\text{Returns}(S_t, A_t)]$ 
11:      $a^* \leftarrow \text{argmax}_a q(S_t, a)$ 
12:      $\epsilon$ -greedy 策略选取  $\pi(a|S_t)$ 

```

4.3 off-policy (离轨) 12

采样与改进不同策略，前者称为行为策略 (Behavior Policy) b (保证对所有可能动作的采样)，后者称为目标策略 (Target Policy) π 。

重要度采样 (IMPORTANCE SAMPLING) 13

计算 G 时，对轨迹在 π 和 b 中出现的相对概率进行加权：

$$\rho_{t:T-1} = \prod_{k=t}^{T-1} \frac{\pi(A_k|S_k)}{b(A_k|S_k)} \text{ (约去相同的转移概率)}$$

- 普通重要度采样: $v(s) \doteq \frac{\sum_{t \in \tau(s)} \rho_{t:T(t)-1} G_t}{|\tau(s)|}$ ，无偏但无界。
- 加权重要度采样: $v(s) \doteq \frac{\sum_{t \in \tau(s)} \rho_{t:T(t)-1} G_t}{\sum_{t \in \tau(s)} \rho_{t:T(t)-1}}$ ，有偏但偏差值渐近收敛。

减小方差的方法见 [12.3.2](#)。

增量式更新

$$v_{n+1} \doteq v_n + \frac{W_n}{C_n} [G_n - v_n] \text{ (} v_n \text{ 和 } G_n \text{ 线性组合)}$$

$$C_{n+1} \doteq C_n + W_{n+1}$$

其中， W_i 是随机权重， C_i 是其累加和。

算法 4: MC-Off-policy (every visit)

```

1: 初始化:  $\forall s \in S, a \in A(s)$ , 任意初始化  $q(s, a) \in \mathbb{R}, C(s, a) = 0$ , 初始化  $\pi(s) =$   

    $\text{argmax}_a q(s, a)$  ▷ 目标策略为贪婪策略

```

算法 4: MC-Off-policy (every visit)

2: 循环

3: 根据b生成一幕序列 $S_0, A_0, R_1, S_1, A_1, R_2, \dots, S_{T-1}, A_{T-1}, R_T$

4: $G \leftarrow 0, W \leftarrow 1$

5: 对于 $t = T - 1, T - 2, \dots, 0$ 执行

6: $G \leftarrow \gamma G + R_{t+1}$

7: $C(S_t, A_t) \leftarrow C(S_t, A_t) + W$

8: $q(S_t, A_t) \leftarrow q(S_t, A_t) + \frac{W}{C(S_t, A_t)}[G - q(S_t, A_t)]$

9: $\pi(S_t) \leftarrow \operatorname{argmax}_a q(S_t, a)$

10: 如果 $A_t \neq \pi(S_t)$ 那么

11: break

12: $W \leftarrow \frac{W}{b(A_t|S_t)}$

▷ 行为策略

▷ 增量式更新

▷ 如果不是最优动作则退出内层循环

▷ 更新重要度采样权重

潜在问题：贪心行为普遍时，只会从幕尾学习；贪心行为不普遍时，学习速度较慢。

4.4 对比

表 2: MC对比

| 策略类型 | 稳定性 | 收敛性 |
|------------|--------------|------------------|
| on-policy | 较稳定 | 需要更多样本（更新需要新的数据） |
| off-policy | 不太稳定（使用行为策略） | 更快找到优质解 |

5 时序差分（TEMPORAL DIFFERENCE，TD）：采样更新

TD可直接从与环境的互动中获取信息，不需要P，同时运用自举思想，可基于已得到的其他状态估计来更新当前 $v(s)$ ，相当于结合了DP和MC的优点。

5.1 TD(0) 14

更新公式为：

$$v_{t+1}(s_t) = v_t(s_t) + \alpha_t(s_t) \underbrace{[r_{t+1} + \gamma v_t(s_{t+1}) - v_t(s_t)]}_{\text{TD目标 (target)}}$$

新息：TD误差 (error) δ_t

- G_t 是 $v_\pi(s_t)$ 的无偏估计； $r_{t+1} + \gamma v_\pi(s_{t+1})$ 是无偏估计，而 $r_{t+1} + \gamma v(s_{t+1})$ 是有偏估计。
- MC误差可写成TD误差之和 $G_t - v(s_t) = \sum_{k=t}^{T-1} \gamma^{k-t} \delta_k$ ，其在步长较小时成立。




图 7: TD回溯图

优势

- 不需要P,R。
- 更新快：MC须等到幕尾确定增量，更新 G_t ；而TD只需等到下一时刻，更新TD目标。
- 方差小：MC更新依赖很多随机动作，TD更新仅依赖一个随机动作，因此TD目标的方差比 G_t 的方差要小很多。
- 自举性：TD需要初始猜测值，MC没有进行初始猜测。
- 只评估当前动作，与后续动作无关。

| 算法 5：TD(0) | |
|------------|--|
| 1: | 输入：待评估策略 π |
| 2: | 参数：步长 $\alpha \in (0, 1]$ |
| 3: | 初始化： $\forall s \in S^+$ ，任意初始化 $v(s), v(\text{终止}) = 0$ |
| 4: | 对于 每一幕 执行 |
| 5: | 初始化 s |
| 6: | 当 s 不是终止状态 执行 |
| 7: | $a \leftarrow \pi(s)$ |
| 8: | 执行动作 a ，观察 r, s' |

算法 5: TD(0)

```

9:       $v(s) \leftarrow v(s) + \alpha[r + \gamma v(s') - v(s)]$ 
10:      $s \leftarrow s'$ 

```

5.2 Sarsa (on-policy-TD) 15

Sarsa (State-Action-Reward-State-Action), 更新单元为 $(s_t, a_t, r_t, s_{t+1}, a_{t+1})$, 是TD算法的 $q(s, a)$ 版本:

$$q_{t+1}(s_t, a_t) = q_t(s_t, a_t) + \alpha_t(s_t, a_t)[r_{t+1} + \gamma q_t(s_{t+1}, a_{t+1}) - q_t(s_t, a_t)]$$



图 8: Sarsa回溯图

算法 6: Sarsa (on-policy-TD)

```

1: 参数: 步长  $\alpha \in (0, 1]$ ,  $\epsilon > 0$ 
2: 初始化:  $\forall s \in S^+$ , 任意初始化  $q(s, a)$ ,  $q(\text{终止}, \cdot) = 0$ 
3: 对于 每一幕 执行
4:   初始化  $s$ 
5:   使用从  $q$  得到的  $\epsilon$ -greedy 策略, 在  $s$  选择  $a$ 
6:   当  $s$  不是终止状态 执行
7:     执行  $a$ , 观察  $r, s'$ 
8:     使用从  $q$  得到的  $\epsilon$ -greedy 策略, 在  $s'$  处选择  $a'$ 
9:      $q(s, a) \leftarrow q(s, a) + \alpha[R + \gamma q(s', a') - q(s, a)]$ 
10:     $s \leftarrow s', a \leftarrow a'$ 

```

期望SARSA 16

$$q_{t+1}(s_t, a_t) = q_t(s_t, a_t) + \alpha_t(s_t, a_t) \{ r_{t+1} + \underbrace{\gamma \left[\sum_a \pi(a|s_{t+1}) q_t(s_{t+1}, a) \right]}_{v_t(s_{t+1})} - q_t(s_t, a_t) \}$$

- 相较Sarsa，期望Sarsa虽然计算复杂，但消除了随机选择带来的方差。
- α 的选择会影响长期稳态性等指标。
- 生成策略可以基于相同或不同策略，即离轨或在轨是可变的，因此Q-learning可视为期望Sarsa的特例。




图 9: 期望Sarsa回溯图

5.3 Q-learning (off-policy-TD) 17

Q-learning旨在求解行为值贝尔曼最优方程，直接逼近 $q^*(s, a)$ ，更新单元为 (s_t, a_t, r_t, s_{t+1}) 。

$$q_{t+1}(s_t, a_t) = q_t(s_t, a_t) + \alpha_t(s_t, a_t)[r_{t+1} + \gamma \max_a q_t(s_{t+1}, a) - q_t(s_t, a_t)]$$




图 10: Q-learning回溯图

算法 7: Q-learning (off-policy-TD)

- 1: 参数: 步长 $\alpha \in (0, 1]$, 探索率 $\epsilon > 0$
- 2: 初始化: $\forall s \in S^+, a \in A(s)$, 任意初始化 $q(s, a)$, $q(\text{终止}, \cdot) = 0$
- 3: 对于 每一幕 执行
 - 4: 初始化 s
 - 5: 当 s 不是终止状态 执行
 - 6: 使用从 q 得到的 ϵ -greedy策略, 在 s 选择 a
 - 7: 执行 a , 观察 r, s'
 - 8: $q(s, a) \leftarrow q(s, a) + \alpha[r + \gamma \max_a q(s', a) - q(s, a)]$
 - 9: $s \leftarrow s'$

双学习：划分样本，学习两个独立的估计 $q_1(a), q_2(a)$ ，确定 $a^* = \operatorname{argmax}_a q_1(a)$ ，再计算 $q_2(a^*) = q_2(\operatorname{argmax}_a q_1(a))$ ，后者是无偏的（可以交换再来一次）。需要双倍内存，但是计算量不会增大。

$$q_{1,t+1}(s_t, a_t) = q_{1,t}(s_t, a_t) + \alpha_t(s_t, a_t) \{r_{t+1} + \gamma q_{2,t}[s_{t+1}, \operatorname{argmax}_a q_{1,t}(s_{t+1}, a)] - q_{1,t}(s_t, a_t)\}$$




图 11: 双Q-learning回溯图

算法 8: 双Q-learning

- 1: 参数: 步长 $\alpha \in (0, 1]$, 探索率 $\epsilon > 0$
- 2: 初始化: $\forall s \in S^+, a \in A(s)$, 任意初始化 $q_1(s, a), q_2(s, a), q_1(\text{终止}, \cdot) = q_2(\text{终止}, \cdot) = 0$
- 3: 对于 每一幕 执行
- 4: 初始化 s
- 5: 当 s 不是终止状态 执行
- 6: 基于 $q_1 + q_2$, 使用 ϵ -greedy策略在 s 选择 a
- 7: 执行 a , 观察 r, s'
- 8: 如果 以0.5的概率 那么
- 9: $q_1(s, a) \leftarrow q_1(s, a) + \alpha[r + \gamma q_2(s', \operatorname{argmax}_a Q_1(s', a)) - Q_1(s, a)]$
- 10: 否则
- 11: $q_2(s, a) \leftarrow q_2(s, a) + \alpha[r + \gamma q_1(s', \operatorname{argmax}_a Q_2(s', a)) - Q_2(s, a)]$
- 12: $s \leftarrow s'$

5.4 对比与补充

Sarsa较为保守，在存在风险的任务中，会避开低回报动作；Q-learning较为乐观，更倾向于探索并找到最优解。在存在陷阱的任务中，Sarsa会比Q-learning取得更好的结果。

补充见12.3.3。

6 N步自举法

6.1 n-TD 19

n-TD作为MC和TD的一般推广，在两种极端方法间找到了性能更好的平衡点。n-TD在n步后进行更新，截断得到n步回报。

$$G_{t:t+n} \doteq r_{t+1} + \gamma r_{t+2} + \cdots + \gamma^{n-1} r_{t+n} + \gamma^n v_{t+n-1}(s_{t+n})$$

其中 $v_{t+n}(s_t) \doteq v_{t+n-1}(s_t) + \alpha[G_{t:t+n} - v_{t+n-1}(s_t)]$ 。

算法 9: n-TD

```

1: 输入: 待评估策略 $\pi$ 
2: 参数: 步长 $\alpha \in (0, 1]$ ,  $n \in \mathbb{N}_+$ 
3: 初始化:  $\forall s \in S$ , 任意初始化 $V(s)$ 
4: 对于 每一幕 执行
5:     初始化 $S_0$ 为非终止状态
6:      $T \leftarrow \infty$ 
7:     对于  $t = 0, 1, 2, \dots$  执行
8:         如果  $t < T$  那么
9:             根据 $\pi(\cdot|S_t)$ 采取动作 $A_t$ 
10:            观察 $R_{t+1}, S_{t+1}$ 
11:            如果  $S_{t+1}$ 是终止状态 那么
12:                 $T \leftarrow t + 1$ 
13:             $\tau \leftarrow t - n + 1$  ▷  $\tau$ 是正在更新的状态的时间
14:            如果  $\tau \geq 0$  那么
15:                 $G \leftarrow \sum_{i=\tau+1}^{\min(\tau+n, T)} \gamma^{i-\tau-1} R_i$ 
16:                如果  $\tau + n < T$  那么
17:                     $G \leftarrow G + \gamma^n V(S_{\tau+n})$ 
18:                 $V(S_\tau) \leftarrow V(S_\tau) + \alpha[G - V(S_\tau)]$ 
19:            如果  $\tau = T - 1$  那么
20:                break

```

6.2 n-Sarsa 20

n-Sarsa统一了Sarsa和MC，其节点转移全部基于采样得到的单独路径：


$$q_{t+n}(s_t, a_t) \doteq q_{t+n-1}(s_t, a_t) + \alpha[G_{t:t+n} - q_{t+n-1}(s_t, a_t)]$$

n-期望Sarsa只对最后一个状态到动作的转移展开：

$$G_{t:t+n} \doteq r_{t+1} + \gamma r_{t+2} + \cdots + \gamma^{n-1} r_{t+n} + \gamma^n q_{\pi}(s_{t+n}, a_{t+n})$$



(a) n-Sarsa



(b) n-期望Sarsa

图 12: n-Sarsa回溯图

算法 10: n-Sarsa

- 1: 参数：步长 $\alpha \in (0, 1]$ ，探索率 $\epsilon > 0$ ，步数 $n \in \mathbb{N}_+$
- 2: 初始化： $\forall s \in S, a \in A$ ，任意初始化 $Q(s, a)$ ，初始化 π （如基于 Q 的 ϵ -greedy策略）
- 3: 对于 每一幕 执行
- 4: 初始化 S_0 为非终止状态
- 5: 根据 $\pi(\cdot|S_0)$ 选取 A_0
- 6: $T \leftarrow \infty$
- 7: 对于 $t = 0, 1, 2, \dots$ 执行
- 8: 如果 $t < T$ 那么
- 9: 执行动作 A_t ，观察 R_{t+1}, S_{t+1}
- 10: 如果 S_{t+1} 是终止状态 那么
- 11: $T \leftarrow t + 1$
- 12: 否则
- 13: 根据 $\pi(\cdot|S_{t+1})$ 选取 A_{t+1}
- 14: $\tau \leftarrow t - n + 1$ ▷ τ 是正在更新的状态的时间

算法 10: n-Sarsa

```

15:    如果  $\tau \geq 0$  那么
16:         $G \leftarrow \sum_{i=\tau+1}^{\min(\tau+n, T)} \gamma^{i-\tau-1} R_i$ 
17:        如果  $\tau + n < T$  那么
18:             $G \leftarrow G + \gamma^n Q(S_{\tau+n}, A_{\tau+n})$ 
19:             $Q(S_\tau, A_\tau) \leftarrow Q(S_\tau, A_\tau) + \alpha[G - Q(S_\tau, A_\tau)]$ 
20:        如果  $\tau = T - 1$  那么
21:            break

```

OFF-POLICY-N-TD

$$v_{t+n}(s_t) \doteq v_{t+n-1}(s_t) + \alpha \rho_{t:t+n-1} [G_{t:t+n} - v_{t+n-1}(s_t)]$$

其中重要度采样率为目标策略和行为策略采取 n 个动作的相对概率:

$$\rho_{t:h} \doteq \prod_{k=t}^{\min(h, T-1)} \frac{\pi(a_k | s_k)}{b(a_k | s_k)}$$

算法 11: n-期望Sarsa-off-policy

```

1: 输入: 行为策略 $b$ , 满足 $b(a|s) > 0$ 
2: 参数: 步长 $\alpha \in (0, 1]$ , 探索率 $\epsilon > 0$ , 步数 $n \in \mathbb{N}_+$ 
3: 初始化:  $\forall s \in S, a \in A$ , 任意初始化 $Q(s, a)$ , 初始化目标策略 $\pi$ 
4: 对于 每一幕 执行
5:     初始化 $S_0$ 为非终止状态
6:     根据 $b(\cdot|S_0)$ 选取 $A_0$ 
7:      $T \leftarrow \infty$ 
8:     对于  $t = 0, 1, 2, \dots$  执行
9:         如果  $t < T$  那么
10:            执行动作 $A_t$ , 观察 $R_{t+1}, S_{t+1}$ 
11:            如果  $S_{t+1}$ 是终止状态 那么
12:                 $T \leftarrow t + 1$ 
13:            否则
14:                根据  $b(\cdot|S_{t+1})$ 选取 $A_{t+1}$ 
15:             $\tau \leftarrow t - n + 1$ 

```

▷ τ 是正在更新的状态的时间

算法 11: n-期望Sarsa-off-policy

```

16:    如果  $\tau \geq 0$  那么
17:         $\rho \leftarrow \prod_{i=\tau+1}^{\min(\tau+n-1, T-1)} \frac{\pi(A_i|S_i)}{b(A_i|S_i)}$  ▷ 重要性采样权重
18:         $G \leftarrow \sum_{i=\tau+1}^{\min(\tau+n, T)} \gamma^{i-\tau-1} R_i$ 
19:        如果  $\tau + n < T$  那么
20:             $G \leftarrow G + \gamma^n \sum_a \pi(a|S_{\tau+n}) Q(S_{\tau+n}, a)$  ▷ 期望Sarsa使用期望值
21:             $Q(S_\tau, A_\tau) \leftarrow Q(S_\tau, A_\tau) + \alpha \rho [G - Q(S_\tau, A_\tau)]$ 
22:        如果  $\tau = T - 1$  那么
23:            break

```

6.3 n-树回溯 ²¹**带控制变量的每次决策模型**

为保证不被选择的动作不会因 $\rho_t = 0$ 而回报为0，使方差较大，采取以下n步回报off-policy方法：

$$G_{t:h} \doteq \rho_t(r_{t+1} + \gamma G_{t+1:h}) + \underbrace{(1 - \rho_t)v_{h-1}(s_t)}_{\text{控制变量}}$$

其中控制变量保证 $\rho_t = 0$ 时估计值不收缩，且不改变更新期望。

可写为以下递归形式：

$$\begin{aligned}
 G_{t:h} &\doteq r_{t+1} + \gamma[\rho_{t+1}G_{t+1:h} + \bar{v}_{h-1}(s_{t+1}) - \rho_{t+1}Q_{h-1}(s_{t+1}, a_{t+1})] \\
 &= r_{t+1} + \gamma\rho_{t+1}[G_{t+1:h} - Q_{h-1}(s_{t+1}, a_{t+1})] + \gamma\bar{v}_{h-1}(s_{t+1})
 \end{aligned}$$

N-树回溯

off-policy因所学内容相关性小，比on-policy慢，一些方法可以缓解这一问题，比如不使用重要度采样的树回溯算法。相比于前面以沿途收益和底部节点估计价值为更新目标的算法，树回溯的更新源于整个树的行为值估计，即各叶子节点的行为值估计按出现概率加权。

单步回溯树：

$$G_{t:t+1} \doteq r_{t+1} + \gamma \sum_a \pi(a|s_{t+1}) Q_t(s_{t+1}, a)$$

拓展到n-回溯树的递归形式，其对路径可能分支进行展开，不进行采样：

$$G_{t:t+n} \doteq r_{t+1} + \gamma \sum_{a \neq a_{t+1}} \pi(a|s_{t+1}) Q_{t+n-1}(s_{t+1}, a) + \gamma \pi(a_{t+1}|s_{t+1}) G_{t+1:t+n}$$




图 13: n-树回溯回溯图

算法 12: n-树回溯

- 1: 参数: 步长 $\alpha \in (0, 1]$, $n \in \mathbb{N}_+$
- 2: 初始化: $\forall s \in S, a \in A$, 任意初始化 $Q(s, a)$, 初始化 π
- 3: 对于 每一幕 执行
- 4: 初始化 S_0 为非终止状态
- 5: 根据 S_0 任意选取 A_0
- 6: $T \leftarrow \infty$
- 7: 对于 $t = 0, 1, 2, \dots$ 执行
- 8: 如果 $t < T$ 那么
- 9: 执行动作 A_t , 观察 R_{t+1}, S_{t+1}
- 10: 如果 S_{t+1} 是终止状态 那么
- 11: $T \leftarrow t + 1$
- 12: 否则
- 13: 根据 S_{t+1} 选取 A_{t+1}
- 14: $\tau \leftarrow t - n + 1$ ▷ τ 是正在更新的状态的时间
- 15: 如果 $\tau \geq 0$ 那么
- 16: 如果 $t + 1 \geq T$ 那么
- 17: $G \leftarrow R_T$
- 18: 否则
- 19: $G \leftarrow R_{t+1} + \gamma \sum_a \pi(a|S_{t+1}) Q(S_{t+1}, a)$
- 20: 对于 $k = \min(t, T - 1)$ 递减到 $\tau + 1$ 执行
- 21: $G \leftarrow R_k + \gamma \sum_{a \neq A_k} \pi(a|S_k) Q(S_k, a) + \gamma \pi(A_k|S_k) G$

算法 12: n-树回溯

```
22:       $Q(S_\tau, A_\tau) \leftarrow Q(S_\tau, A_\tau) + \alpha[G - Q(S_\tau, A_\tau)]$ 
23:      如果  $\tau = T - 1$  那么
24:          break
```

6.4 n-Q(σ) ²²

结合采样的Sarsa和展开的树回溯，在每个状态由参数 σ 决定是采样还是展开，将两种线性情况组合起来：

$G_{t:h} \doteq r_{t+1} + \gamma(\sigma_{t+1}\rho_{t+1} + (1 - \sigma_{t+1})\pi(a_{t+1}|s_{t+1}))(G_{t+1:h} - Q_{h-1}(s_{t+1}, a_{t+1})) + \gamma\bar{v}_{h-1}(s_{t+1})$




图 14: Q(σ)回溯图

算法 13: n-Q(σ)-off-policy

```
1: 输入: 行为策略b, 满足b(a|s) > 0
2: 参数: 步长 $\alpha \in (0, 1]$ , 探索率 $\epsilon > 0$ , 步数 $n \in \mathbb{N}_+$ 
3: 初始化:  $\forall s \in S, a \in A$ , 任意初始化 $Q(s, a)$ , 初始化目标策略 $\pi$ 
4: 对于 每一幕 执行
5:     初始化 $S_0$ 为非终止状态
6:     根据b( $\cdot|S_0$ )选取 $A_0$ 
7:      $T \leftarrow \infty$ 
8:     对于  $t = 0, 1, 2, \dots$  执行
9:         如果  $t < T$  那么
10:            执行动作 $A_t$ , 观察 $R_{t+1}, S_{t+1}$ 
11:            如果  $S_{t+1}$ 是终止状态 那么
12:                 $T \leftarrow t + 1$ 
```

算法 13: n-Q(σ)-off-policy

```

13:         否则
14:             根据  $b(\cdot|S_{t+1})$  选取  $A_{t+1}$ 
15:             选择  $\sigma_{t+1}$  ▷ 指示是采样还是展开
16:              $\rho_{t+1} \leftarrow \frac{\pi(A_{t+1}|S_{t+1})}{b(A_{t+1}|S_{t+1})}$  ▷ 重要性采样比率
17:          $\tau \leftarrow t - n + 1$  ▷  $\tau$  是正在更新的状态的时间
18:         如果  $\tau \geq 0$  那么
19:              $G \leftarrow 0$ 
20:             对于  $k = \min(t, T - 1)$  递减到  $\tau + 1$  执行
21:                 如果  $k = T$  那么
22:                      $G \leftarrow R_T$ 
23:                 否则
24:                      $\bar{V} \leftarrow \sum_a \pi(a|S_k) Q(S_k, a)$  ▷ 计算期望状态值
25:                      $G \leftarrow R_k + \gamma[\sigma_k \rho_k + (1 - \sigma_k) \pi(A_k|S_k)][G - Q(S_k, A_k)] + \gamma \bar{V}$ 
26:                      $Q(S_\tau, A_\tau) \leftarrow Q(S_\tau, A_\tau) + \alpha[G - Q(S_\tau, A_\tau)]$ 
27:             如果  $\tau = T - 1$  那么
28:                 break

```

7 表格型方法总结对比

基于模型的方法（DP、启发式搜索）主要进行规划，无模型的方法（MC、TD）主要进行学习，二者的核心都是值函数的计算。

表格型方法介绍 见[12.3.4](#)

三个维度 23

- 更新：期望更新能产生更好的估计，但是需要更多的计算。
- 自举程度。
- 同轨/离轨。

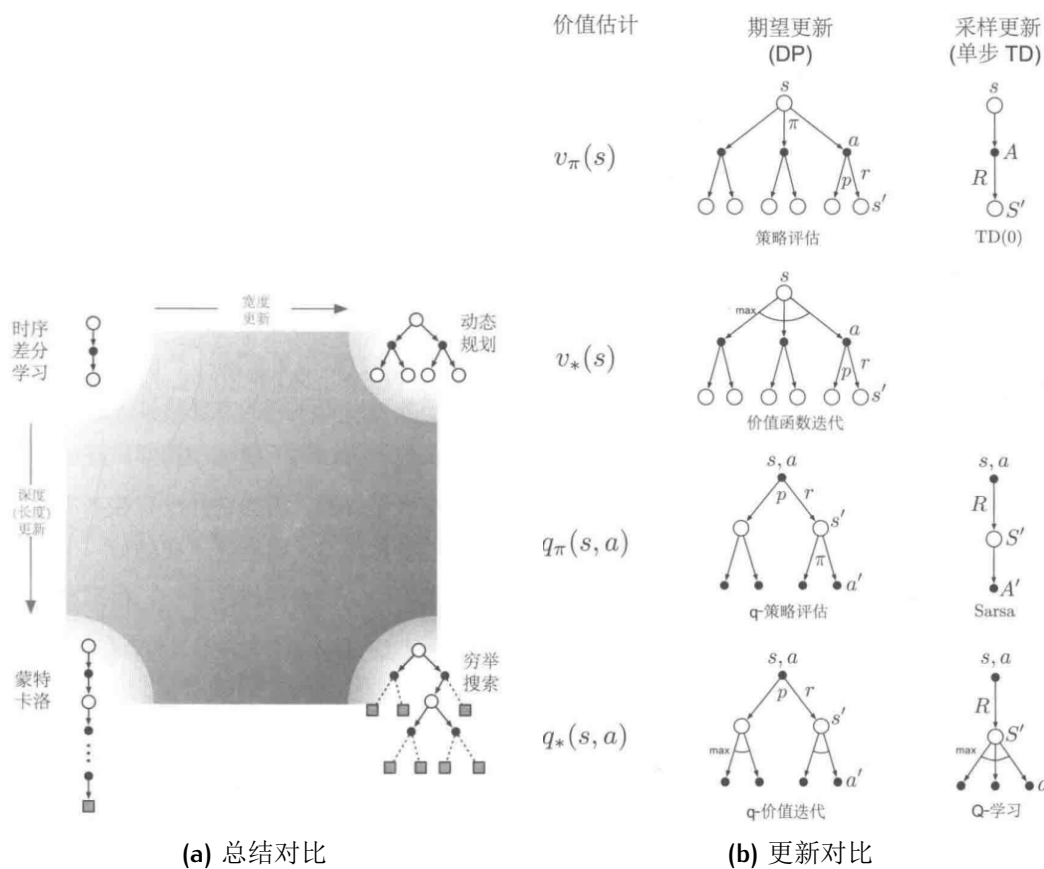


图 15: 表格型方法对比




图 16: 表达式对比

表达式对比 统一格式:

$$q_{t+1}(s_t, a_t) = q_t(s_t, a_t) + \alpha_t(s_t, a_t)[\bar{q}_t - q_t(s_t, a_t)]$$

表 3: 各算法中的 \bar{q}_t 表达式

| 算法 | \bar{q}_t 表达式 | 求解目标 |
|------------|--|---------|
| Sarsa | $r_{t+1} + \gamma q_t(s_{t+1}, a_{t+1})$ | 贝尔曼方程 |
| n-Sarsa | $r_{t+1} + \gamma r_{t+2} + \cdots + \gamma^n q_t(s_{t+n}, a_{t+n})$ | |
| 期望Sarsa | $r_{t+1} + \gamma \sum_{a \in A} \pi_t(a s_{t+1}) q_t(s_{t+1}, a)$ | |
| Q-learning | $r_{t+1} + \gamma \max_a q_t(s_{t+1}, a)$ | 贝尔曼最优方程 |
| MC | $r_{t+1} + \gamma r_{t+2} + \cdots$ | 贝尔曼方程 |

8 值函数近似

8.1 函数近似

$$\hat{v}(s, w) \approx v_\pi(s), w \in \mathbb{R}^d, d \ll |S|$$

目标函数

$$J(w) = E[(v_\pi(S) - \hat{v}(S, w))^2]$$

在对状态按重要程度进行加权后，可得到均方值误差：

$$\overline{VE}(w) \doteq \sum_{s \in S} \mu(s) [v_\pi(s) - \hat{v}(s, w)]^2$$

一般无法保证最优，求解局部最优。

状态分布

- 均匀分布（各状态同等重要）： $J(w) = \frac{1}{|S|} \sum_{s \in S} [v_\pi(s) - \hat{v}(s, w)]^2$ 。
- 平稳分布（马氏过程长期行为）： $J(w) = \sum_{s \in S} d_\pi(s) [v_\pi(s) - \hat{v}(s, w)]^2$ 。

优势

- 具有一定泛化能力，适应部分观测问题。
- 曲线拟合：用少量参数储存状态，阶数越高越近似。

8.2 随机梯度下降 (SGD) 24

$$\omega_{k+1} = \omega_k - \alpha_k \nabla_{\omega} J(\omega_k)$$

其中,

$$\begin{aligned} \nabla_{\omega} J(\omega) &= \nabla_{\omega} E[(v_{\pi}(S) - \hat{v}(S, \omega))^2] \\ &= E[\nabla_{\omega} (v_{\pi}(S) - \hat{v}(S, \omega))^2] \text{ (有界可换求导与期望顺序)} \\ &= -2E[(v_{\pi}(S) - \hat{v}(S, \omega)) \nabla_{\omega} \hat{v}(S, \omega)] \end{aligned}$$

因此 $\omega_{k+1} = \omega_k + \alpha(v_{\pi}(s_k) - \hat{v}(s_k, \omega_k)) \nabla_{\omega} \hat{v}(s_k, \omega_k)$ 。

负梯度方向降速最快 梯度方向增长最快，负梯度方向下降最快。

步长 α

近似方法

- $v_{\pi}(s_t)$:
 - 蒙特卡洛: g_t 。
 - 时序差分: $r_{t+1} + \gamma \hat{v}(s_{t+1}, \omega_t)$ 。
- $\hat{v}(S, \omega)$:
 - 线性参数: $\hat{v}(S, \omega) = \phi(S)^T \omega$, $\phi(S)$ 为特征函数。可采用多项式基函数、傅里叶基函数或径向基函数，表格法可视为其特殊情况。可以使用最小二乘法来减少迭代产生的计算量。
 - 非线性参数: 神经网络，输入状态，网络参数为 ω ，输出 $\hat{v}(S, \omega)$ 。
 - 核函数（见12.4）、高斯回归等非参数方法。

半梯度方法 只考虑 w_t 对估计值的影响，而忽略对目标的影响。在使用自举目标时，目标本身依赖于当前 w ，这使得它们有偏。

- 优势: 学习速度较快，支持持续在线学习，无需等待幕结束。
- 局限: 稳健性差，在非线性函数近似中可能不稳定。

算法 14：梯度蒙特卡洛

- 1: 输入：待评估 π ，可微函数 $\hat{v}: S \times \mathbb{R}^d \rightarrow \mathbb{R}$
- 2: 参数：步长 $\alpha > 0$
- 3: 初始化：任意初始化 $w \in \mathbb{R}^d$
- 4: 循环 ▷ 对每一幕
- 5: 根据 π 生成一幕交互数据 $S_0, A_0, R_1, S_1, A_1, \dots, R_T, S_T$
- 6: 对于 $t = 0, 1, \dots, T-1$ 执行
- 7: $w \leftarrow w + \alpha[G_t - \hat{v}(S_t, w)]\nabla \hat{v}(S_t, w)$

算法 15：半梯度TD(o)

- 1: 输入：待评估 π ，可微函数 $\hat{v}: S^+ \times \mathbb{R}^d \rightarrow \mathbb{R}, \hat{v}(\text{终止}, \cdot) = 0$
- 2: 参数：步长 $\alpha > 0$
- 3: 初始化：任意初始化 $w \in \mathbb{R}^d$
- 4: 循环 ▷ 对每一幕
- 5: 初始化 S
- 6: 对于 $t = 0, 1, \dots, T-1$ 执行
- 7: 选取 $A \sim \pi(\cdot|S)$ 并采取，观察 R, S'
- 8: $w \leftarrow w + \alpha[R + \gamma \hat{v}(S', w) - \hat{v}(S, w)]\nabla \hat{v}(S, w)$
- 9: $S \leftarrow S'$
- 10: 如果 S' 为终止状态 那么
- 11: break

8.3 DQN (Deep Q-Network) 25

DQN用神经网络作为非线性函数近似器，最小化损失函数（贝尔曼最优性误差），适用于高维空间的状态和动作问题：

$$J(w) = E\{[R + \gamma \max_{a'} \hat{q}(S', a', \underbrace{w^-}_{\text{目标网络}}) - \hat{q}(S, A, \underbrace{w}_{\text{主网络}})]^2\}$$

主要技术

- 两个网络：主网络 $\hat{q}(S, A, w)$ 和目标网络 $\hat{q}(S', a', w^-)$ ，后者参数阶段性从前者同步。
 - 防止过拟合：

- * 随机丢弃法 (dropout)。
 - * 批量归一化 (batch normalization)。
 - * 残差直连边。
- 更新：
- * 软更新：部分更新。
 - * 硬更新：直接复制。
- 经验回放 (Experience Replay)：存储经验到固定大小的回放缓冲区，训练时从中随机选取。可以打乱样本相关性，提升训练稳定性，可改进为优先经验回放。
 - 帧堆叠：将图像作为神经网络输入时，堆叠多帧图像作为输入，并跳帧选取放入帧，增加时间信息。
 - 奖励裁剪 (Reward Clipping)：将奖励限制在特定范围内（甚至使用符号函数），避免大奖励幅度波动，提升训练稳定性，适用于奖励范围差异大的环境。

算法 16: DQN

```

1: 初始化主网络参数 $\omega$ 和目标网络参数 $\omega^-$ 
2: 初始化经验回放缓冲区 $B = \{(s, a, r, s')\}$ 
3: 初始化计数器 $t \leftarrow 0$ 
4: 循环
5:   如果  $t \bmod C = 0$  那么                                ▷ 每隔C步更新目标网络（初始化一致）
6:      $\omega^- \leftarrow \omega$ 
7:   从B中均匀采样小批量样本 $\{(s, a, r, s')\}$ 
8:   对于 每个样本 $(s, a, r, s')$  执行
9:     如果  $s'$  是终止状态 那么
10:       $y \leftarrow r$ 
11:     否则
12:       $y \leftarrow r + \gamma \max_{a'} \hat{q}(s', a', \omega^-)$                                 ▷ 计算目标值
13:   使用小批量样本 $\{(s, a, y)\}$ 更新主网络参数 $\omega$ ，最小化损失 $(y - \hat{q}(s, a, \omega))^2$ 
14:    $t \leftarrow t + 1$ 

```

DOUBLE-DQN 两个值函数逼近网络，一个选择动作，一个评估值函数。

9 策略梯度 (POLICY GRADIENT)

9.1 概念 26

将策略参数化，在策略空间进行搜索：

$$\pi(a|s, \theta) = \pi_{\theta}(a|s)$$

是同轨策略。

目标 学习 θ 使以下指标最大。

- 平均状态价值：

$$\bar{v}_{\pi} = \sum_{s \in S} d(s) v_{\pi}(s) = E[d(S) v_{\pi}(S)]$$

其中 $d(s) \geq 0$ 为 s 的权重， $\sum_{s \in S} d(s) = 1$ ，其可以由以下方法选取：

- 同等重要： $d(s) = \frac{1}{|S|}$ 。
- 只关心 s_0 ： $d(s_0) = 1, d(s \neq s_0) = 0$ 。
- 平稳分布： $d_{\pi}^T P_{\pi} = d_{\pi}^T$ ，根据访问频次赋予概率。

- 平均单步奖励：

$$\begin{aligned} \bar{r}_{\pi} &= \sum_{s \in S} d_{\pi}(s) \underbrace{r_{\pi}(s)}_{\sum_{a \in A} \pi(a|s) r(s,a)} = E[d_{\pi}(S) r_{\pi}(S)] \\ &= \lim_{n \rightarrow \infty} \frac{1}{n} E\left[\sum_{k=1}^n R_{t+k}\right] = \lim_{n \rightarrow \infty} \frac{1}{n} E\left[\sum_{k=1}^n R_{t+k} | S_t = s_0\right] \end{aligned}$$

其中 $d_{\pi}(s)$ 为平稳分布。

梯度

$$\begin{aligned} \nabla_{\theta} J(\theta) &= \sum_{s \in S} d(s) \sum_{a \in A} \nabla_{\theta} \pi(a|s, \theta) q_{\pi}(s, a) \\ &= \sum_s d(s) \sum_a \pi(a|s, \theta) \nabla_{\theta} \ln \pi(a|s, \theta) q_{\pi}(s, a) \\ &= E_{S \sim d, A \sim \pi} [\nabla_{\theta} \ln \pi(A|S, \theta) q_{\pi}(S, A)] \end{aligned}$$

为确保 $\pi(a|s, \theta) > 0$ ，使用softmax函数， $\pi(a|s, \theta) = \frac{e^{h(s,a,\theta)}}{\sum_{a' \in A} e^{h(s,a',\theta)}}$ 。

梯度上升算法

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \nabla_{\theta} J(\theta) = \theta_t + \alpha E[\nabla_{\theta} \ln \pi(A|S, \theta_t) q_{\pi}(S, A)] \\ &= \theta_t + \alpha \underbrace{\nabla_{\theta} \ln \pi(a_t|s_t, \theta_t)}_{\beta_t = \frac{q_{\pi}(s_t, a_t)}{\pi(a_t|s_t, \theta_t)}} \underbrace{q_{\pi}(s_t, a_t)}_{q(s_t, a_t) \text{ 近似}} \text{ (随机梯度)}\end{aligned}$$

- $\alpha\beta_t$ 足够小时，若 $\beta_t > 0$ ，则选择 (s_t, a_t) 的概率增加，且幅度与 β_t 正相关。
- β_t 与 $q_{\pi}(s_t, a_t)$ 正相关，与 $\pi(a_t|s_t, \theta_t)$ 负相关，倾向于选择高价值动作，探索低概率动作。

优势

- 可以逼近确定性策略。
- 可以逼近任意概率分布，不受 $q(s, a)$ 限制。
- 策略是更简单的函数逼近，如PID控制。
- 策略参数化更容易加入先验知识。
- 在状态空间大时，存储和泛化能力强。

9.2 REINFORCE (MC-policy gradient) 27

用蒙特卡洛方法估计 $q_{\pi}(s, a)$ ，使用与 θ 无关的 G_t 代替 $q_{\pi}(s_t, a_t)$ ：

$$\theta_{t+1} \doteq \theta_t + \alpha G_t \nabla_{\theta} \ln \pi(a_t|s_t, \theta_t)$$

算法 17: REINFORCE

- 1: 输入：可微分的参数化策略 $\pi(a|s, \theta)$
- 2: 参数：步长 $\alpha > 0$ ，折扣因子 $\gamma \in (0, 1)$
- 3: 初始化：初始化策略参数 $\theta \in \mathbb{R}^{d'}$
- 4: 循环 ▷ 对每一幕循环
- 5: 按照 $\pi(\cdot|\cdot, \theta)$ 生成一幕 $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$
- 6: 对于 $t = 0, 1, \dots, T-1$ 执行
- 7: $G_t \leftarrow \sum_{k=t+1}^T \gamma^{k-t-1} R_k$ ▷ (G_t)

算法 17: REINFORCE

8: $\theta \leftarrow \theta + \alpha G_t \nabla_{\theta} \ln \pi(a_t | s_t, \theta_t)$

10 ACTOR-CRITIC方法**10.1 概念 28**

结合策略梯度和价值方法。

$$\theta_{t+1} = \theta_t + \alpha \nabla_{\theta} \ln \pi(a_t | s_t, \theta_t) q_{\pi}(s_t, a_t)$$

- 演员 (Actor): 策略更新, 用于采取行动, 对应算法更新。
- 评论家 (Critic): 策略评估或价值估计, 用于评判策略, 对应估计 $q_{\pi}(s, a)$, 采用TD方法。

算法 18: QAC

```

1: 初始化: 策略参数 $\theta$ 和评论家参数 $w$ 
2: 对于 每个回合 执行
3:   对于  $t = 0, 1, 2, \dots, T-1$  执行
4:     根据策略 $\pi(a|s_t, \theta_t)$ 选择 $a_t$ , 观察 $r_{t+1}, s_{t+1}$ , 再根据策略 $\pi(a|s_{t+1}, \theta_t)$ 选择 $a_{t+1}$ 
5:      $\delta_t = r_{t+1} + \gamma q(s_{t+1}, a_{t+1}, w_t) - q(s_t, a_t, w_t)$  ▷ TD误差
6:      $w_{t+1} = w_t + \alpha_w \delta_t \nabla_w q(s_t, a_t, w_t)$  ▷ 评论家价值更新
7:      $\theta_{t+1} = \theta_t + \alpha_{\theta} \nabla_{\theta} \ln \pi(a_t | s_t, \theta_t) q(s_t, a_t, w_{t+1})$  ▷ 演员策略更新

```

10.2 优势Actor-Critic方法 (A2C) 29

基本的Actor-Critic方法有较大方差, 引入基线降低。

10.2.1 基线 30

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{S \sim \eta, A \sim \pi} \{ \nabla_{\theta} \ln \pi(A | S, \theta_t) [q_{\pi}(S, A) - b(S)] \}$$

策略梯度不变

$$\begin{aligned}
 E_{S \sim \eta, A \sim \pi}[\nabla_{\theta} \ln \pi(A|S, \theta_t) b(S)] &= \sum_{s \in S} \eta(s) \sum_{a \in A} \nabla_{\theta} \pi(a|s, \theta_t) b(s) \\
 &= \sum_{s \in S} \eta(s) b(s) \sum_{a \in A} \nabla_{\theta} \pi(a|s, \theta_t) \\
 &= \sum_{s \in S} \eta(s) b(s) \nabla_{\theta} 1 \text{ (交换求和与求导)} \\
 &= 0
 \end{aligned}$$

策略梯度方差最小化 求偏导获得：

$$\begin{aligned}
 b^*(s) &= \frac{E_{A \sim \pi}[\|\nabla_{\theta} \ln \pi(A|s, \theta_t)\|^2 q_{\pi}(s, A)]}{E_{A \sim \pi}[\|\nabla_{\theta} \ln \pi(A|s, \theta_t)\|^2]} \\
 &= E_{A \sim \pi}[q_{\pi}(s, A)] \text{ (省略权重)} \\
 &= v_{\pi}(s)
 \end{aligned}$$

如果直接用 $b(s) = q_{\pi}(s, a)$ ，会导致策略梯度为0。

优势函数

$$\theta_{t+1} = \theta_t + \alpha E\{\nabla_{\theta} \ln \pi(A|S, \theta_t) \underbrace{[q_{\pi}(S, A) - v_{\pi}(s)]}_{\text{优势函数 } \delta_{\pi}(S, A)}\}$$

此时， $\beta_t = \frac{\delta_{\pi}(s_t, s_t)}{\pi(a_t|s_t, \theta_t)}$ ，正相关项为相对值，而非绝对值，更合理，仍能平衡探索和利用。

使用TD方法进行近似，有：

$$\delta_t = q_t(s_t, a_t) - v_t(s_t) \approx r_{t+1} + \gamma v_t(s_{t+1}) - v_t(s_t)$$

这时只需要一个网络进行估计。

算法 19: A2C

- 1: 初始化：策略参数 θ 和评论家参数 w
- 2: 对于 每个回合 执行
- 3: 对于 $t = 0, 1, 2, \dots, T-1$ 执行
- 4: 根据策略 $\pi(a|s_t, \theta_t)$ 选择 a_t ，执行后观察 r_{t+1}, s_{t+1}
- 5: $\delta_t = r_{t+1} + \gamma v(s_{t+1}, w_t) - v(s_t, w_t)$ ▷ 优势函数
- 6: $w_{t+1} = w_t + \alpha_w \delta_t \nabla_w v(s_t, w_t)$ ▷ 评论家价值更新

算法 19: A2C

7: $\theta_{t+1} = \theta_t + \alpha_\theta \delta_t \nabla_\theta \ln \pi(a_t | s_t, \theta_t)$ ▷ 演员策略更新

10.3 离轨Actor-Critic方法 31

加入重要性采样变成离轨方法:

$$\nabla_\theta J(\theta) = \mathbb{E}_{S \sim \rho, A \sim \beta} \left[\frac{\pi(A|S, \theta)}{\beta(A|S)} \nabla_\theta \ln \pi(A|S, \theta) q_\pi(S, A) \right]$$

其中 β 是行为策略, ρ 是状态分布。其也可以采用上述基线 $b^*(s)$ 。

算法 20: 重要性采样离轨Actor-Critic

1: 初始化: 给定行为策略 $\beta(a|s)$ 、目标策略 $\pi(a|s, \theta_0)$ 、值函数 $v(s, w_0)$
 2: 对于 每个回合 执行
 3: 对于 $t = 0, 1, 2, \dots, T-1$ 执行
 4: 根据 $\beta(s_t)$ 选择 a_t , 观察 r_{t+1}, s_{t+1} 。
 5: $\delta_t = r_{t+1} + \gamma v(s_{t+1}, w_t) - v(s_t, w_t)$ ▷ 优势函数
 6: $w_{t+1} = w_t + \alpha_w \frac{\pi(a_t | s_t, \theta_t)}{\beta(a_t | s_t)} \delta_t \nabla_w v(s_t, w_t)$ ▷ 评论家价值更新
 7: $\theta_{t+1} = \theta_t + \alpha_\theta \frac{\pi(a_t | s_t, \theta_t)}{\beta(a_t | s_t)} \delta_t \nabla_\theta \ln \pi(a_t | s_t, \theta_t)$ ▷ 演员策略更新

10.4 确定性策略Actor-Critic方法 (DPG) 32

$$\nabla_\theta J(\theta) = \sum_{s \in S} \rho_\mu(s) \nabla_\theta \mu(s) (\nabla_a q_\mu(s, a)) \Big|_{a=\mu(s)} = \mathbb{E}_{S \sim \rho_\mu} [\nabla_\theta \mu(S) (\nabla_a q_\mu(S, a)) \Big|_{a=\mu(S)}]$$

其中, ρ_μ 是一种状态分布。

算法 21: 确定性策略离轨Actor-Critic

1: 初始化: 给定行为策略 $\beta(a|s)$ 、确定性目标策略 $\mu(s, \theta_0)$ 、值函数 $q(s, a, w_0)$ 。
 2: 对于 每个回合 执行
 3: 对于 $t = 0, 1, 2, \dots, T-1$ 执行
 4: 根据 $\beta(s_t)$ 生成 a_t , 观察 r_{t+1}, s_{t+1}

| 算法 21：确定性策略离轨Actor-Critic | | |
|---------------------------|--|-----------|
| 5: | $\delta_t = r_{t+1} + \gamma q(s_{t+1}, \mu(s_{t+1}, \theta_t), w_t) - q(s_t, a_t, w_t)$ | ▷ 优势函数 |
| 6: | $w_{t+1} = w_t + \alpha_w \delta_t \nabla_w q(s_t, a_t, w_t)$ | ▷ 评论家价值更新 |
| 7: | $\theta_{t+1} = \theta_t + \alpha_\theta \nabla_\theta \mu(s_t, \theta_t) (\nabla_a q(s_t, a, w_{t+1})) _{a=\mu(s_t)}$ | ▷ 演员策略更新 |

11 策略搜索方法总结对比



12 附录

12.1 历史与发展

1. 源于动物学习心理学的试错法：效应定律（Edward Thorndike），条件反射（巴普洛夫），快乐-痛苦系统（图灵），向“老师”学习到向“评论家”学习，自动学习机（M.L.Tsetlin），分类器系统（救火队算法和遗传算法）。
2. 最优控制：贝尔曼方程与马尔可夫决策过程（Richard Bellman），维度灾难。
3. 时序差分方法：次级强化物，广义强化（Klopf），与试错法结合（actor-critic方法，Sutton），与最优控制结合（Q-learning，Chris Watkins）。

返回正文1。

12.2 贝尔曼最优方程求解

收缩映射定理 若 $f(x)$ 是收缩映射，则存在唯一一个不动点 x^* 满足 $f(x^*) = x^*$ 。针对 $x_{k+1} = f(x_k)$ ，在 $x_k \rightarrow x^*, k \rightarrow \infty$ 的过程中，收敛速度成指数级增长。

- 存在性： $\|x_{k+1} - x_k\| = \|f(x_{k+1}) - f(x_k)\| \leq \gamma \|x_k - x_{k-1}\| \leq \dots \leq \gamma^k \|x_1 - x_0\| \xrightarrow{\gamma < 1, \gamma^k \rightarrow 0} x_{k+1} - x_k \rightarrow 0$ 。同理可得 $\|x_m - x_n\| \leq \frac{\gamma^n}{1-\gamma} \|x_1 - x_0\| \rightarrow 0$ ，进而得到 $\{x_k\}$ 是收敛数列，存在 $\lim_{k \rightarrow \infty} x_k = x^*$ 。
- 唯一性： $\|f(x_k) - x_k\| = \|x_{k+1} - x_k\|$ ，其快速收敛到0，则在极限处有不动点 $f(x^*) = x^*$ 。假设存在另一不动点，其必与该不动点相等。
- 指数级收敛： $\|x^* - x_n\| = \lim_{m \rightarrow \infty} \|x_m - x_n\| \leq \frac{\gamma^n}{1-\gamma} \|x_1 - x_0\| \rightarrow 0$ 。

贝尔曼最优方程的伸缩映射性

$\forall v_1, v_2$ ，有贝尔曼最优方程 $\pi_i^* \doteq \arg \max_{\pi} (r_{\pi} + \gamma P_{\pi} v_i)$ ，

故 $f(v_i) = \max_{\pi} (r_{\pi} + \gamma P_{\pi} v_i) = r_{\pi_i^*} + \gamma P_{\pi_i^*} v_i \geq r_{\pi_j^*} + \gamma P_{\pi_j^*} v_i (i \neq j)$ ，则

$$\begin{aligned} f(v_1) - f(v_2) &= r_{\pi_1^*} + \gamma P_{\pi_1^*} v_1 - (r_{\pi_2^*} + \gamma P_{\pi_2^*} v_2) \\ &\leq r_{\pi_1^*} + \gamma P_{\pi_1^*} v_1 - (r_{\pi_1^*} + \gamma P_{\pi_1^*} v_2) \\ &= \gamma P_{\pi_1^*} (v_1 - v_2) \end{aligned}$$

同理有 $f(v_2) - f(v_1) \leq \gamma P_{\pi_2^*} (v_2 - v_1)$ ，故 $\gamma P_{\pi_2^*} (v_1 - v_2) \leq f(v_1) - f(v_2) \leq \gamma P_{\pi_1^*} (v_1 - v_2)$ ，

取边界极值 z ，有 $|f(v_1) - f(v_2)| \leq z$ ，即 $\|f(v_1) - f(v_2)\|_{\infty} \leq \|z\|_{\infty}$ 。

又有 $\|z\|_{\infty} = \max_i |z_i| \leq \gamma \|v_1 - v_2\|_{\infty}$ ，所以 $\|f(v_1) - f(v_2)\|_{\infty} \leq \gamma \|v_1 - v_2\|_{\infty}$ 。

贝尔曼最优方程解的性质

- 唯一性：唯一解 v^* 能通过 $v_{k+1} = f(v_k) = \max_{\pi \in \Pi} (r_{\pi} + \gamma P_{\pi} v_k)$ 迭代求解，其对应策略 $\pi^* = \arg \max_{\pi \in \Pi} (r_{\pi} + \gamma P_{\pi} v^*)$ 。
- 最优性 ($v^* = v_{\pi^*} \geq v_{\pi}$)：由 $v_{\pi} = r_{\pi} + \gamma P_{\pi} v_{\pi}$ 和 $v^* = \max_{\pi} (r_{\pi} + \gamma P_{\pi} v^*) = r_{\pi^*} + \gamma P_{\pi^*} v^* \geq r_{\pi} + \gamma P_{\pi} v^*$ ，可得 $v^* - v_{\pi} \geq (r_{\pi} + \gamma P_{\pi} v^*) - (r_{\pi} + \gamma P_{\pi} v_{\pi}) = \gamma P_{\pi} (v^* - v_{\pi})$ ，即有 $v^* - v_{\pi} \geq \gamma P_{\pi} (v^* - v_{\pi}) \geq \dots \geq \gamma^n P_{\pi}^n (v^* - v_{\pi})$ ，由于 $\gamma < 1, \forall p_{ij} \in P_{\pi}, p_{ij} \leq 1$ ， $\lim_{n \rightarrow \infty} \gamma^n P_{\pi}^n (v^* - v_{\pi}) \rightarrow 0$ ，所以 $v^* \geq v_{\pi}$ 。

返回正文[2.2.2](#)。

12.3 表格型方法

12.3.1 DP补充

1. 异步动态规划：使用任意可用状态值，以任意顺序更新，避免遍历更新，减小计算量。
2. 广义策略迭代（GPI）：策略评估和策略改进以更细粒度进行交替，可视为竞争与合作。
3. 效率：DP的时间复杂度是动作与状态数量的多项式级，在面对维度灾难时，优于线性规划和直接搜索。

返回正文[3.3](#)。

12.3.2 MC补充

减小重要性采样的方差

- 折扣敏感：把 γ 视作幕终止的概率，得到第 n 步终止的无折扣部分回报 $\sum_{i=1}^n R_{t+i}$ ，即平价部分回报。全回报 $G_t = \sum_{i=1}^{T-t} \gamma^{i-1} R_{t+i}$ 可视为各平价部分回报的加权和，即该步截止得到的回报与概率之积的和。适用于普通型和加权型。
- 每次决策型： $E[\rho_{t:T-1} G_t] = E[\tilde{G}_t] = E[\sum_{i=1}^{T-t} \gamma^{i-1} \rho_{t:t+i-1} R_{t+i}]$ 。适用于普通型。

返回正文[13](#)。

12.3.3 TD补充

- 随机游走：在随机任务实践中，TD(0)的收敛速度要比常量 α MC快。这是因为前者的最优性与预测回报更相关，找出的是完全符合马尔可夫过程模型的最大似然估计参数，收敛到确定性等价估计；而后者只在有限方面最优，找出的是最小化训练集均方误差的估计。
- 批量更新：值函数根据增量和改变，在处理整批数据后才更新。
- 最大化偏差：贪心策略和柔性策略都在隐式估计最大值，会产生正偏差，致使回报值偏离，带来明显错误决策。
- 后位状态：利用先验知识，知晓动作后状态，并有后位值函数。在后位状态相同的时候可以迁移，减少计算量。

返回正文[5.4](#)。

12.3.4 模型和规划

模型

- 分布模型：生成所有可能的结果的描述与概率分布。
- 样本模型：从所有可能中按概率分布采样一个确定结果。可由分布模型生成，一般更容易获得。

规划

- 规划：以环境模型为输入，生成或改进与其交互的策略。
- 规划空间：
 - 状态空间规划：在状态空间搜索最优策略。
 - 方案空间规划：进化算法、偏序规划。
- 规划时间：
 - 后台规划：从环境模型生成模拟经验，改进策略或值函数。
 - 决策时规划：使用模拟经验为状态选择动作。

统一的状态空间规划算法 通过仿真经验的回溯操作计算值函数，进而改进策略。

模型 \implies 模拟经验 $\overset{\text{回溯}}{\implies}$ 值函数 \implies 策略

12.3.5 Dyna-Q

学习和规划由相同算法完成，真实经验用于学习，模拟经验用于规划。

| 算法 22: Dyna-Q | | |
|--|--|---------------------------|
| 1: 初始化: $\forall s \in S, a \in A(s)$, 初始化 $Q(s, a)$ 和 $Model(s, a)$ | | |
| 2: 循环 | | |
| 3: $s \leftarrow$ 当前（非终止）状态 | | ▷ 学习 |
| 4: 基于 (s, Q) 选取 a , 执行后观察 r, s' | | ▷ 可用 ϵ -greedy策略 |
| 5: $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_a Q(s', a) - Q(s, a)]$ | | ▷ 直接强化学习更新 |
| 6: $Model(s, a) \leftarrow r, s'$ | | |
| 7: 对于 $i = 1, \dots, n$ 执行 | | ▷ 规划 |

算法 22: Dyna-Q

| | | |
|-----|---|-----------|
| 8: | 随机选择已观测过的 s 和其下采取过的 a | |
| 9: | $r, s' \leftarrow \text{Model}(s, a)$ | ▷ 从模型获取预测 |
| 10: | $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_a Q(s', a) - Q(s, a)]$ | ▷ 规划更新 |

12.3.6 改进方法

鼓励长期未出现动作，模型可能不正确，需规避在次优解收敛。

优先遍历 集中更新有收益动作，而非均匀采样。

关联前导动作和前导状态，在后续动作有收益时先更新前导动作价值，进行有效更新。按照价值改变多少对状态-动作对进行优先级排序，并由后至前反向传播出高影响序列。

算法 23: 确定性环境下的优先遍历

| | | |
|-----|---|---------------------------|
| 1: | 初始化: $\forall s \in S, a \in A(s)$, 初始化 $Q(s, a), \text{Model}(s, a)$, 初始化优先级队列 $\text{PQueue} = \text{NULL}$ | |
| 2: | 循环 | |
| 3: | $s \leftarrow$ 当前（非终止）状态 | |
| 4: | 基于 (s, q) 选取 a , 执行后观察 r, s' | ▷ 可用 ϵ -greedy策略 |
| 5: | $\text{Model}(s, a) \leftarrow r, s'$ | |
| 6: | $P \leftarrow r + \gamma \max_a Q(s', a) - Q(s, a) $ | ▷ 优先级 |
| 7: | 如果 $P > 0$ 那么 | |
| 8: | 将 (s, a) 以优先级 P 插入 PQueue | |
| 9: | 对于 $i = 1, \dots, n$ 执行 | |
| 10: | 如果 $\text{PQueue} = \text{NULL}$ 那么 | |
| 11: | break | |
| 12: | $(s, a) \leftarrow \text{PQueue}(0)$ | ▷ 最高优先级 |
| 13: | $r, s' \leftarrow \text{Model}(s, a)$ | ▷ 从模型获取预测 |
| 14: | $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_a Q(s', a) - Q(s, a)]$ | ▷ 规划更新 |
| 15: | 对于 每个可达到 s 的 (\bar{s}, \bar{a}) 执行 | ▷ 反向传播更新 |
| 16: | $\bar{r}, \bar{s}' \leftarrow \text{Model}(\bar{s}, \bar{a})$ | |
| 17: | 如果 $\bar{s}' = s$ 那么 | |

算法 23：确定性环境下的优先遍历

18: $P \leftarrow |\bar{r} + \gamma \max_a Q(s, a) - Q(\bar{s}, \bar{a})|$

19: 如果 $P > 0$ 那么

20: 将 (\bar{s}, \bar{a}) 以优先级 P 插入 $PQueue$

ON-POLICY 轨迹采样 借助模拟生成经验回溯更新，能跳过无关状态，获得最优部分策略。实时动态规划（RTDP）是其异步值迭代版本，可在较少访问频率下找到最优策略，并且产生轨迹所用的策略也会接近最优策略。

启发式搜索 聚焦于当前状态。

预演算法 作为MC的特例，通过平均多个起始于可能动作并遵循给定策略的模拟轨迹的回报来估计行为值。蒙特卡洛树搜索（MCTS）通过累积蒙特卡洛值估计来不断优化模拟轨迹的收益。

返回正文7。

12.4 核函数近似

- 基于记忆样本，使用RBF核，存储样本状态。核函数 $k(s, s')$ 可表示为特征向量 $x(s)$ 的内积，每个特征对应一个样本状态：

$$k(s, s') = x(s)^T x(s')$$

- 非参数化，不需要学习参数。
- 避免高维计算，高效处理特征。
- 线性参数化方法皆可重塑为核函数，相同训练数据下会得到近似结果。

返回正文8.2。

12.5 数学基础

概率空间 (Ω, F, P)

- 性质
 - 非负性: $\forall A \in \mathcal{F}, P(A) \geq 0$ 。
 - 规范性: $P(\Omega) = 1$ 。
 - 可列可加性: 若 A_1, A_2, \dots 互斥, 则 $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$ 。
- 运算
 - 补集: $P(A^c) = 1 - P(A)$ 。
 - 交集: $P(A \cap B) = P(A) + P(B) - P(A \cup B)$ 。

随机变量

- 离散型
 - 概率质量函数(PMF): $P(X = x) = p(x), \sum_x p(x) = 1$ 。
 - 期望: $E[X] = \sum_x x p(x)$ 。
- 连续型
 - 概率密度函数(PDF): $f(x) \geq 0, \int_{-\infty}^{\infty} f(x) dx = 1$ 。
 - 期望: $E[X] = \int_{-\infty}^{\infty} x f(x) dx$ 。
- 方差: $\text{Var}(X) = E[(X - E[X])^2]$ 。

条件概率与独立性

- 条件概率: $P(B|A) = \frac{P(A \cap B)}{P(A)}, P(A) > 0$ 。
- 全概率公式: $P(B) = \sum_{A \in \mathcal{F}} P(B|A)P(A)$ 。
- 贝叶斯定理: $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$ 。
- 独立性: A, B 独立 $\iff P(A \cap B) = P(A)P(B)$ 。
- 条件独立: $P(A, B|C) = P(A|C)P(B|C)$ 。

大数定律与中心极限定理

- 弱大数律: $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p} E[X]$ 。
- 强大数律: $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{a.s.} E[X]$ 。
- 中心极限定理: X_1, X_2, \dots 独立同分布, 均值为 μ , 方差为 $\sigma^2 < \infty$, 则 $\frac{1}{\sqrt{n}} \sum_{i=1}^n (X_i - \mu) \xrightarrow{d} N(0, \sigma^2)$ 。

泛函分析

- 期望的线性: $E[aX + bY] = aE[X] + bE[Y]$ 。
- 协方差: $\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E[XY] - \mu_X \mu_Y$ 。
- 相关系数: $\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$ 。