

# 智能工程

# 目 录

1	基础知识	4	5.1.6	性能对比	22
2	机器人运动学	5	5.2	定位与匹配	22
2.1	运动学模型	5	5.2.1	基于SVD的定位算法	22
2.2	车轮	5	5.2.2	基于ICP的点云匹配算法	24
2.3	运动学建模	6	6	机器人定位	24
2.3.1	空间描述与状态表达	6	6.1	定位与导航	24
2.3.2	瞬心法	7	6.2	贝叶斯定位	25
2.3.3	约束方程法	7	6.3	基于卡尔曼滤波的定位	26
2.3.4	例子	9	6.3.1	卡尔曼滤波	26
2.4	自由度	10	6.3.2	基于卡尔曼滤波的定位 算法	28
3	机器人运动控制	11	6.4	蒙特卡洛定位	29
3.1	运动控制	11	6.4.1	蒙特卡洛方法	29
3.2	定点控制器	12	6.4.2	蒙特卡洛定位算法（粒 子滤波算法）	29
3.3	轨迹跟踪控制器	13	6.4.3	自适应蒙特卡洛定位算法	31
3.4	路径跟踪控制器	14	7	机器人建图	32
4	机器人感知	15	7.1	地图	32
4.1	传感器	15	7.2	SLAM	34
4.2	光电传感器	16	7.3	基于滤波的SLAM算法	34
4.2.1	概述	16	7.3.1	EKF-SLAM	34
4.2.2	编码器	16	7.3.2	FastSLAM	37
4.3	里程计	17	7.4	基于优化的SLAM算法	38
4.3.1	里程计模型	17	7.5	LOAM	40
4.3.2	里程计误差	18	8	机器人运动规划	40
4.4	激光传感器	19	8.1	运动规划	40
5	机器人点云处理	20	8.2	基于图搜索的路径规划	41
5.1	直线提取	20	8.2.1	静态路径规划	41
5.1.1	最小二乘法	20	8.2.2	动态路径规划	42
5.1.2	Split-and-Merge	20	8.3	基于采样的路径规划	43
5.1.3	Line-Regression	20	8.4	面向碰撞的局部路径规划	44
5.1.4	RANSAC	21	8.5	路径平滑	44
5.1.5	Hough-Transform	21	8.6	轨迹规划	44

9 附录	44	9.2 奇异值分解	45
9.1 误差转化展示	44		

## 图 片

图 1	课程内容	4	图 6	两轮差速机器人正运动学建模	9
图 2	两轮差速机器人模型	4	图 7	运动控制器	11
图 3	车轮类型	5	图 8	里程计建模方法	17
图 4	瞬心	7	图 9	里程计误差转化展示	19
图 5	车轮约束示意图	8	图 10	卡尔曼滤波框图	27
			图 11	基于卡尔曼滤波的定位算法示意图	28
			图 12	图优化例题	39

## 表 格

表 1	课程内容	4	表 3	车轮约束方程	8
表 2	车轮类型对比	6	表 4	传感器分类	15
			表 5	直线特征提取算法性能对比	22
			表 6	卡尔曼滤波算法描述维度	28
			表 7	图搜索算法对比	42

## 要 点

要点 1	非完整约束	5	要点 13	最小二乘法矩阵形式求解	20
要点 2	车轮类型	5	要点 14	Split-and-Merge直线提取	20
要点 3	瞬心法运动学建模	7	要点 15	RANSAC直线提取	21
要点 4	约束方程法运动学建模	7	要点 16	基于SVD的定位算法	22
要点 5	自由度	10	要点 17	基于ICP的点云匹配算法	24
要点 6	定点控制器（误差信号转换）	12	要点 18	卡尔曼滤波迭代公式	27
要点 7	轨迹跟踪控制器	13	要点 19	基于卡尔曼滤波的定位算法	28
要点 8	路径跟踪控制器	14	要点 20	蒙特卡洛定位算法（粒子滤波算法）	29
要点 9	传感器	15	要点 21	自适应蒙特卡洛定位算法	31
要点 10	编码器	16	要点 22	EKF-SLAM	34
要点 11	里程计建模方法	17	要点 23	FastSLAM	37
要点 12	误差传播	18	要点 24	图优化例题	39
			要点 25	图搜索算法	41

1 基础知识




图 1: 课程内容

	$u_i$	$u_o$	R	F	$u_r$	$e$	C
概念	系统输入	系统输出	系统模型	反馈单元	系统给定	系统误差	控制器
含义	对被控对象施加作用的手段	作业目标的可测系统状态	系统输入输出映射	系统输出映射变换	系统作业目标	作业目标与系统当前测量状态差值	系统误差与输入映射
内容	机器人运动学			机器人控制		机器人感知	机器人运动规划

表 1: 课程内容

课程内容

课程案例 移动机器人->轮式机器人->两轮差速机器人。




图 2: 两轮差速机器人模型

- 车轮半径 $r$ 。
  - 两轮转速 $\varphi_l, \varphi_r$ :  $v_i = r\varphi_i$ 。
  - 车轮到两轮中间点距离 $l$ 。
1. 正运动学模型2.3.4。
  2. 运动控制器3.1。
  3. 里程计模型4.3.1。

## 2 机器人运动学

### 2.1 运动学模型

表征机器人驱动（输入）和机器人空间位姿（输出）的关系。

#### 机械臂与移动机器人的区别

- 机械臂本体坐标系固定，精度高；移动机器人本体坐标系随动，精度低。
- 非完整约束<sup>1</sup>：移动机器人只知道码盘变化量无法获取位姿，状态取决于路径，源于不可积的微分约束（车轮侧向滑动约束）。
- 微分运动学（Differential Kinematics）：速度空间替代位置空间。

### 2.2 车轮

#### 类型<sup>2</sup>

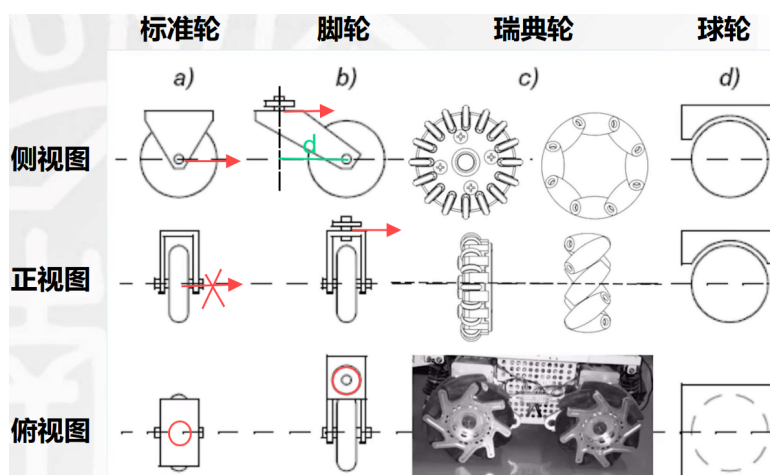


图 3: 车轮类型

类型	自由度	约束	分类/特点
标准轮 (Standard wheel)	2 沿轮平面滚动 沿垂直轴转动	1 沿轮轴滑动	标准固定轮（无法旋转，只有一个自由度） 标准转向轮（舵轮）
脚轮 (Castor wheel)	3 沿轮平面滚动 沿垂直轴转动 沿路轴运动	0	偏心距 <b>d</b> : 触地点到垂直旋转轴距离。 扭矩压力，易损坏。
瑞典轮 (Swedish wheel)	3 沿轮平面滚动（被动） 沿轮轴转动（主动） 沿垂直轴转动（被动）	0	麦克纳姆轮（Macanum wheel）: 45，至少需要4个共同使用。 连续切换轮：90，至少需要3个共同使用。 对地面冲击大，噪音大，易损坏，成本高。
球轮 (Spherical wheel)	3（全主动） 沿两个正交轮轴转动 沿垂直轴转动	0	成本高，可靠性差。

表 2: 车轮类型对比

选取

- 数量：至少三轮同时着地，才能保证静态稳定性。四轮可以提升稳定性，但需要悬架。
- 大小：越大的轮子通过性越好，但需要更大的扭矩。
- 多数形态都有非完整约束。

2.3 运动学建模

2.3.1 空间描述与状态表达

坐标系

- 惯性系I: 作业目标、控制指令、传感器感知测量信息。
- 机器人系R: 控制器误差输入、控制器控制指令。

- 笛卡尔系：右手法则。

## 位姿 (POSE)

位置空间求导得到速度空间：

$$\xi_I = \begin{bmatrix} x_I \\ y_I \\ \theta_I \end{bmatrix}, \xi_R = \begin{bmatrix} x_R \\ y_R \\ \theta_R \end{bmatrix} \xrightarrow{\text{求导}} \dot{\xi}_I = \begin{bmatrix} \dot{x}_I \\ \dot{y}_I \\ \dot{\theta}_I \end{bmatrix}, \dot{\xi}_R = \begin{bmatrix} \dot{x}_R \\ \dot{y}_R \\ \dot{\theta}_R \end{bmatrix}$$

惯性系旋转得到机器人系：

$$\dot{\xi}_R = R(\theta) \dot{\xi}_I$$

$$\text{旋转阵 } R(\theta) = \begin{bmatrix} \cos \theta & \sin \theta & 0 \\ -\sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \text{ 为单位正交阵, } R^T = R^{-1}.$$

### 2.3.2 瞬心 (ICR) 法 <sup>3</sup>

#### 瞬时旋转/曲率中心 (ICR)

刚体上各点角速度相同。




图 4: 瞬心

#### 步骤

1. 坐标系变换。
2. 确定约束。
3. 确定瞬心：各轮轮轴到该点距离与速度成正比。
4. 求解  $\dot{\xi}_R = \begin{bmatrix} \dot{x}_R & \dot{y}_R & \dot{\theta}_R \end{bmatrix}^T$ 。

### 2.3.3 约束方程法 <sup>4</sup>

**要求** 在水平面上运动，车轮与地面点接触，不变形，安装在钢体表面，舵机转轴与地面垂直。




图 5: 车轮约束示意图

类型	约束	约束方程	主动轮	随动轮
标准轮	纯滚动	$\begin{bmatrix} \sin(\alpha + \beta(t)) & -\cos(\alpha + \beta(t)) & -l \cos \beta(t) \end{bmatrix} R \theta \dot{\xi}_I = r \dot{\phi}$	✓	x
	无滑动	$\begin{bmatrix} \cos(\alpha + \beta(t)) & \sin(\alpha + \beta(t)) & l \sin \beta(t) \end{bmatrix} R \theta \dot{\xi}_I = 0$	✓	✓
脚轮	纯滚动	$\begin{bmatrix} \sin(\alpha + \beta) & -\cos(\alpha + \beta) & -l \cos \beta \end{bmatrix} R \theta \dot{\xi}_I = r \dot{\phi}$	✓	x
	无滑动	$\begin{bmatrix} \cos(\alpha + \beta) & \sin(\alpha + \beta) & d + l \sin \beta \end{bmatrix} R \theta \dot{\xi}_I = -d \dot{\beta}$	✓	x
瑞典轮	纯滚动	$\begin{bmatrix} \cos(\alpha + \beta + \gamma) & \sin(\alpha + \beta + \gamma) & l \sin(\beta + \gamma) \end{bmatrix} R \theta \dot{\xi}_I = r \dot{\phi} \sin \gamma + r_{sw} \dot{\phi}_{sw}$	✓	x
	无滑动	$\begin{bmatrix} \sin(\alpha + \beta + \gamma) & -\cos(\alpha + \beta + \gamma) & -l \cos(\beta + \gamma) \end{bmatrix} R \theta \dot{\xi}_I = r \dot{\phi} \cos \gamma$	✓ 小轮	x

表 3: 车轮约束方程

## 约束方程

**使用** 根据各轮主/随动状态列运动约束方程，得到最多三个独立约束方程（对应平面三维位姿）。

以下以N个标准轮（ $N_f$ 个固定， $N_s$ 个转向）机器人为例：

### ● 滚动约束

$$J_1(\beta_s)R(\theta)\dot{\xi}_I - J_2\dot{\phi} = 0$$

其中  $J_1(\beta_s) = \begin{bmatrix} J_{1f}(N_f \times 3) \\ J_{1s}(\beta_s)_{(N_s \times 3)} \end{bmatrix}$ ,  $\phi(t) = \begin{bmatrix} \phi_f(t) \\ \phi_s(t) \end{bmatrix}$ ,  $J_2 = \text{diag}(r_1, \dots, r_N)$  为轮径对角阵。



- 滑动约束

$$C_1(\beta_s)R(\theta)\dot{\xi}_I = 0$$

$$\text{其中 } C_1(\beta_s) = \begin{bmatrix} C_{1f}(N_f \times 3) \\ C_{1s}(\beta_s)_{(N_s \times 3)} \end{bmatrix}。$$

### 2.3.4 例子

以下以两轮差速机器人（见1）为例， $\alpha = \frac{\pi}{2}, \beta = 0$ ：

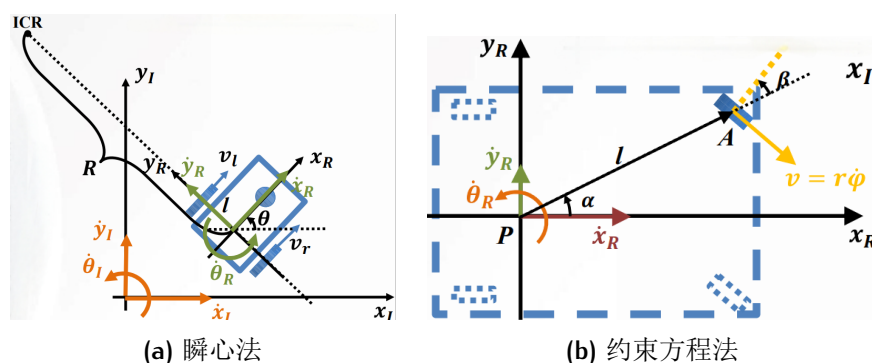


图 6: 两轮差速机器人正运动学建模

### 瞬心法

两轮差速机器人的瞬心在两轮的轮轴上，设其到机器人两轮中间的距离为R，有：

$$\dot{\theta} = \frac{\dot{x}_R}{R} = \frac{\dot{\phi}_l r}{R-l} = \frac{\dot{\phi}_r r}{R+l}$$

解得  $R = \frac{\dot{\phi}_r + \dot{\phi}_l}{\dot{\phi}_r - \dot{\phi}_l}$ ，代回即可。

### 约束方程法

- 纯滚动：  $\begin{bmatrix} \sin(\alpha + \beta) & -\cos(\alpha + \beta) & -l \cos \beta \end{bmatrix} \dot{\xi}_R = r \dot{\phi}。$
- 无滑动：  $\begin{bmatrix} \cos(\alpha + \beta) & \sin(\alpha + \beta) & l \sin \beta \end{bmatrix} \dot{\xi}_R = 0。$

### 正运动学模型

$$\dot{\xi}_R = \begin{bmatrix} \dot{x}_R \\ \dot{y}_R \\ \dot{\theta}_R \end{bmatrix} = \frac{r}{2} \begin{bmatrix} \dot{\phi}_l + \dot{\phi}_r \\ 0 \\ \frac{\dot{\phi}_r - \dot{\phi}_l}{l} \end{bmatrix}$$

## 2.4 自由度

### 概念

- 衡量机器人改变运行状态的能力。
- 需满足实际作业需求，考虑实现成本。
- 机器人设计基础、算法依据（一般同自由度机器人可采用相同控制规划算法）。
- 平面运动机器人自由度最大不能超过3。

### 分类 5

- 移动度（Degree of Mobility） $\delta_m$ ：瞬时改变机器人运动状态的能力。

$$\delta_m = \dim[C_1(\beta_s)] = 3 - \text{rank}[C_1(\beta_s)] \in [0, 3]$$

- 转向度（Degree of Steerability） $\delta_s$ ：间接改变机器人运动状态的能力。

$$\delta_s = \text{rank}[C_{1s}(\beta_s)] \in [0, 2]$$

- 机动度（Degree of Maneuverability） $\delta_M$ ：改变机器人运动状态的能力。

$$\delta_M = \delta_m + \delta_s$$

- 机动度相同，结构不一定相同。
- $\delta_M = 2$ ，瞬心位于一条直线上； $\delta_M = 3$ ，瞬心可分布于空间任何一点。

### 实例（TYPE(移动度,转向度)）

- 全向机器人：
  - Type(3,0)：完整约束全方位移动机器人。
  - Type(2,1)：一个同心轮+两个瑞典轮。
  - Type(1,2)：多舵机全方位移动机器人。
- 非全向机器人：
  - Type(2,0)：差分移动机器人。
  - Type(1,1)：自动驾驶汽车（阿克曼转向）、自行车、叉车。

## 3 机器人运动控制

### 3.1 运动控制

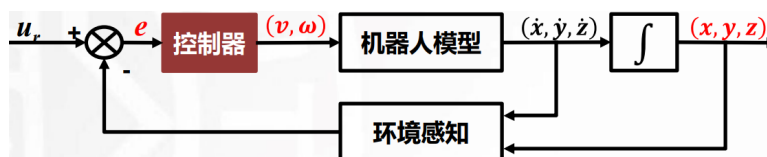


图 7: 运动控制器

误差（惯性系下给定与反馈） $\xrightarrow{\text{变换}}$ 输入（机器人系下控制输入）。

#### 特点

- 大多存在滑动约束，是非完整系统，有侧向和姿态偏差。
- 非线性，控制器设计复杂，还需要根据可获得的反馈信号选取，按顺序调节控制参数，并且不能同时实现定点控制和跟踪控制。
- 不存在能完成控制目标的连续时不变（静态）反馈控制率。
- 受标定精度影响大，且由于执行单元性能约束，控制输入要合理限幅。

#### 分类

- 定点（镇定）控制（Regulation Control）：以指定姿态到达指定位置。
- 跟踪控制：
  - 轨迹跟踪控制（Trajectory Tracking Control）：跟随给定轨迹（速度+姿态）。
  - 路径跟踪控制（Path Tracking Control）：跟随给定路线。

**开环控制** 将运动轨迹分割成直线和圆弧，存在以下问题：

- 直线和圆弧的曲率不一致，不连续。
- 难以实现定义若干合适轨迹。
- 速度加速度约束。

- 无法自适应调整轨迹来面对环境变化。
- 所得轨迹不光滑。

**控制器性能评价** 取正定李雅普诺夫函数，其导数负定则系统渐进稳定。

**两轮差速机器人运动控制** 以下以两轮差速机器人（见1）为例。

$$\dot{\xi}_R = \begin{bmatrix} \dot{x}_R \\ \dot{y}_R \\ \dot{\theta}_R \end{bmatrix} = \frac{r}{2} \begin{bmatrix} \dot{\phi}_l + \dot{\phi}_r \\ 0 \\ \frac{\dot{\phi}_r - \dot{\phi}_l}{l} \end{bmatrix} = \begin{bmatrix} v_1 \\ 0 \\ v_2 \end{bmatrix} \xrightarrow{\text{变换}} \dot{\xi}_I = \begin{bmatrix} \dot{x}_I \\ \dot{y}_I \\ \dot{\theta}_I \end{bmatrix} = \begin{bmatrix} \cos \theta & 0 \\ \sin \theta & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

### 3.2 定点控制器 <sup>6</sup>

**控制目标** 机器人参考坐标系下误差  $e = [x \ y \ \theta]^T$ ，设计控制阵  $K = \begin{bmatrix} k_{11} & k_{12} & k_{13} \\ k_{21} & k_{22} & k_{23} \end{bmatrix}$ ，其中  $k_{ij} = k(t, e)$ ，得到控制输入  $\begin{bmatrix} v(t) \\ \omega(t) \end{bmatrix} = Ke$ ，使  $\lim_{t \rightarrow \infty} e(t) = 0$ 。

#### 误差信号转换

惯性系下，实际状态  $q = [x \ y \ \theta]^T$  与参考状态  $q_r = [x_r \ y_r \ \theta_r]^T$  之差为开环误差  $\tilde{q} = [\tilde{x} \ \tilde{y} \ \tilde{\theta}]^T = [x - x_r \ y - y_r \ \theta - \theta_r]^T$ 。

##### 1. 转换到机器人系

$$e = \begin{bmatrix} e_1 \\ e_2 \\ e_3 \end{bmatrix} = R(\theta)^T \tilde{q} = \begin{bmatrix} \cos \theta & \sin \theta & 0 \\ -\sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \tilde{x} \\ \tilde{y} \\ \tilde{\theta} \end{bmatrix} \xrightarrow{\text{闭环}} \dot{e} = \begin{bmatrix} \dot{e}_1 \\ \dot{e}_2 \\ \dot{e}_3 \end{bmatrix} = R(\theta) \dot{\tilde{q}} + R(\dot{\theta}) \tilde{q} = \begin{bmatrix} v_1 + v_2 e_2 \\ -v_2 e_1 \\ v_2 \end{bmatrix}$$

##### 2. 转换到极坐标系

$$\begin{cases} \rho = \sqrt{\tilde{x}^2 + \tilde{y}^2} \\ \beta = -\arctan 2(-\tilde{y}, -\tilde{x}) \\ \alpha = -\beta - \tilde{\theta} \end{cases} \xrightarrow{\text{闭环}} \begin{bmatrix} \dot{\rho} \\ \dot{\beta} \\ \dot{\alpha} \end{bmatrix} = \begin{bmatrix} -\cos \alpha & 0 \\ \frac{\sin \alpha}{\rho} & 0 \\ \frac{\sin \alpha}{\rho} & -1 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

### 机器人系非线性控制器

设计控制器  $\begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} -k_1 e_1 \\ -k_2 e_2 + e_2^2 \sin(t) \end{bmatrix}$ , 代入得  $\begin{bmatrix} \dot{e}_1 \\ \dot{e}_2 \\ \dot{e}_3 \end{bmatrix} = \begin{bmatrix} -k_1 e_1 + v_2 e_2 \\ -v_2 e_1 \\ -k_2 e_2 + e_2^2 \sin(t) \end{bmatrix}$ , 其有误差

时扰动, 效果不佳。

### 极坐标系线性控制器

设计控制器  $\begin{cases} v_1 = k_\rho \rho \\ v_2 = k_\alpha \alpha + k_\beta \beta \end{cases}$ , 代入得

$$\begin{bmatrix} \dot{\rho} \\ \dot{\beta} \\ \dot{\alpha} \end{bmatrix} = \begin{bmatrix} -k_\rho \rho \cos \alpha \\ -k_\rho \sin \alpha \\ k_\rho \sin \alpha - k_\alpha \alpha - k_\beta \beta \end{bmatrix} \xrightarrow{\alpha \rightarrow 0} \begin{bmatrix} -k_\rho \rho \\ -k_\rho \alpha \\ k_\rho \alpha - k_\alpha \alpha - k_\beta \beta \end{bmatrix}$$

其中前两行非线性耦合, 在  $\alpha \rightarrow 0$  时指数性稳定, 非全局稳定。

### 极坐标系线性控制器

设计控制器  $\begin{cases} v_1 = k_\rho \rho \cos \alpha \\ v_2 = k_\alpha \alpha + \frac{k_\rho \sin \alpha \cos \alpha}{\alpha} (\alpha - k_\beta \beta) \end{cases}$ , 代入得

$$\begin{bmatrix} \dot{\rho} \\ \dot{\beta} \\ \dot{\alpha} \end{bmatrix} = \begin{bmatrix} -k_\rho \rho \cos^2 \alpha \\ -k_\rho \cos \alpha \sin \alpha \\ k_\rho \cos \alpha \sin \alpha - k_\alpha \alpha - \frac{k_\rho \sin \alpha \cos \alpha}{\alpha} (\alpha - k_\beta \beta) \end{bmatrix} \xrightarrow{\alpha \rightarrow 0} \begin{bmatrix} -k_\rho \rho \\ -k_\rho \alpha \\ -k_\alpha \alpha + k_\rho k_\beta \beta \end{bmatrix}$$

其全局渐近稳定。

## 3.3 轨迹跟踪控制器 <sup>7</sup>

### 控制目标与误差变换

惯性系下, 实际轨迹  $q(t) = [x(t) \ y(t) \ \theta(t)]^T$  与参考轨迹  $q_r [x_r(t) \ y_r(t) \ \theta_r(t)]^T$  之差为开环误差  $\tilde{q}(t) = [\tilde{x}(t) \ \tilde{y}(t) \ \tilde{\theta}(t)]^T = [x(t) - x_r(t) \ y(t) - y_r(t) \ \theta(t) - \theta_r(t)]^T$ , 控制目标为  $\lim_{n \rightarrow \infty} \tilde{q}(t) = 0$ 。

辅助误差信号为:

$$e = \begin{bmatrix} \cos \theta & \sin \theta & 0 \\ -\sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \tilde{x} \\ \tilde{y} \\ \tilde{\theta} \end{bmatrix} \xrightarrow{\text{闭环}} \dot{e} = \begin{bmatrix} v_1 + v_2 e_2 - v_{1r} \cos e_3 \\ -v_2 e_1 + v_{1r} \sin e_3 \\ v_2 - v_{2r} \end{bmatrix}$$

### 控制器

设计控制器  $\begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} -k_1 e_1 + v_{1r} \cos e_3 \\ -v_{1r} \frac{\sin e_3}{e_3} e_2 - k_2 e_3 + v_{2r} \end{bmatrix}$ , 代入得  $\begin{bmatrix} \dot{e}_1 \\ \dot{e}_2 \\ \dot{e}_3 \end{bmatrix} = \begin{bmatrix} -k_1 e_1 + v_2 e_2 \\ -v_2 e_1 + v_{1r} \sin e_3 \\ -k_2 e_3 - v_{1r} \frac{\sin e_3}{e_3} e_2 \end{bmatrix}$ 。

$e_3 \rightarrow 0$  时, 控制器简化为  $\begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} -k_1 e_1 + v_{1r} \\ -v_{1r} e_2 + v_{2r} \end{bmatrix}$ , 代入得  $\begin{bmatrix} \dot{e}_1 \\ \dot{e}_2 \\ \dot{e}_3 \end{bmatrix} = \begin{bmatrix} -k_1 e_1 + v_2 e_2 \\ -v_2 e_1 \\ -k_2 e_3 - v_{1r} e_2 \end{bmatrix}$ 。

## 3.4 路径跟踪控制器 <sup>8</sup>

### 控制目标与误差变换

惯性系下, 实际路径  $q(s) = [x(s) \ y(s) \ \theta(s)]^T$  与参考路径  $q_r [x_r(s) \ y_r(s) \ \theta_r(s)]^T$  之差为开环误差  $\tilde{q}(s) = [\tilde{x}(s) \ \tilde{y}(s) \ \tilde{\theta}(s)]^T = [x(s) - x_r(s) \ y(s) - y_r(s) \ \theta(s) - \theta_r(s)]^T$ , 其中  $s \in [0, 1]$  为路径参考变量, 控制目标为  $\lim_{n \rightarrow \infty} \tilde{q}(s) = 0$ 。

作变换  $\begin{cases} y_1 = x + b \cos \theta \\ y_2 = y + b \sin \theta \end{cases}$ , 进而得到闭环误差  $\begin{bmatrix} \dot{y}_1 \\ \dot{y}_2 \end{bmatrix} = \begin{bmatrix} \cos \theta & -b \sin \theta \\ \sin \theta & b \cos \theta \end{bmatrix} \begin{bmatrix} v \\ \omega \end{bmatrix} = T(\theta) \begin{bmatrix} v \\ \omega \end{bmatrix}$ 。

逆运算得到  $\begin{bmatrix} v \\ \omega \end{bmatrix} = T^{-1}(\theta) \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = \begin{bmatrix} \cos \theta & \sin \theta \\ -\frac{\sin \theta}{b} & \frac{\cos \theta}{b} \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix}$ , 故  $\begin{cases} \dot{y}_1 = u_1 \\ \dot{y}_2 = u_2 \\ \dot{\theta} = \frac{u_2 \cos \theta - u_1 \sin \theta}{b} \end{cases}$ 。

### 控制器

设计控制器  $\begin{cases} u_1 = \dot{y}_{1d} + k_1(y_{1d} - y_1) \\ u_2 = \dot{y}_{2d} + k_2(y_{2d} - y_2) \end{cases}$ , 有  $\begin{cases} \dot{\tilde{y}}_1 = -k_1 \tilde{y}_1 \\ \dot{\tilde{y}}_2 = -k_2 \tilde{y}_2 \end{cases}$ , 系统指数性收敛。

## 4 机器人感知

### 4.1 传感器 <sup>9</sup>

分类	传感器	感受	源	分类	传感器	感受	源
触觉	接触开关，碰撞器	EC	P	测距	反射率传感器	EC	A
	光学屏障	EC	A		超声波传感器	EC	A
	非接触式接近传感器	EC	A		激光测距仪	EC	A
轮/电机	电刷编码器	PC	P		光学三角测量	EC	A
	电位计	PC	P		结构光	EC	A
	同步器，旋转变压器	PC	P	运动	多普勒雷达（Rader）	EC	A
	光电编码器	PC	P		多普勒声波	EC	A
	磁编码器	PC	P		激光雷达（Laser）	EC	A
	电感编码器	PC	P		里程计（Odometer）	PC	P
	电容编码器	PC	P		惯导系统（IMU）	PC	P
方向	罗盘（Compass）	EC	P	信标	GPS	EC	A
	陀螺仪（Gyroscope）	PC	P		有源光学或射频信标	EC	A
	倾角仪	EC	A/P		有源超声波信标	EC	A
视觉	相机（Camera）	EC	P		有源光学或射频信标	EC	A
	视觉测距套件	EC	P		反射信标	EC	A
	目标跟踪套件	EC	P				

表 4: 传感器分类

#### 分类

- PC（Proprioceptive，本体感受）/EC（Exteroceptive，外感受）。
- A（Active，有源）/P（Passive，无源）。

#### 特性

- 测量范围：测量上下界之差。
- 动态范围：测量范围上下界比率，常用对数表示，单位为dB。

- 分辨率：最小可测量变化量，一般为动态范围下界。
- 线性度：输入输出信号的映射关系。

## 4.2 光电传感器

### 4.2.1 概述

把被测量变化转换成光信号变化，再转换成电信号。

**组成** 辐射源、光学通路、光电器件。

### 特性

- 不受电磁干扰影响。
- 非接触测量。
- 频谱宽，高精度，高分辨率，高可靠性，发应快。

### 4.2.2 编码器 <sup>10</sup>

测量系统相对运动角度，具有高精度、高分辨率和高可靠性。按结构可分为接触式、光电式和电磁式，后两种为非接触式编码。

### 增量式旋转编码器

- 不能直接输出数字编码，需要数字电路。
- 原理：遮光周期性变化，莫尔条纹明暗交替，电压周期性变化 $U_0 = U_m \cos(\frac{2\pi}{W}x)$ ，形成脉冲，根据脉冲数量可推算旋转角度，位置数据是相对的，掉电后需要复位。
- 辨向：为判断光栅移动方向，使用D触发器整合两个光栅的信息。
  - D触发器：时钟信号有效时， $Q = D$ 。
  - 边缘D触发器：时钟信号处于有效边沿时， $Q = D$ 。



## 绝对式光电编码器

- 能直接输出某种码制的数码，掉电后不需要复位。
- 格雷码（余3循环码）：任意相邻数只有一位二进制数不同，可以由二进制码按位异或（第一位保留）获得，属于可靠性编码，求反方便。

## 4.3 里程计

### 4.3.1 里程计模型

**两轮差速机器人里程计模型** 以下以两轮差速机器人（见1）为例。

$$\dot{\xi}_R = \begin{bmatrix} \dot{x}_R \\ \dot{y}_R \\ \dot{\theta}_R \end{bmatrix} = \frac{r}{2} \begin{bmatrix} \dot{\phi}_l + \dot{\phi}_r \\ 0 \\ \frac{\dot{\phi}_r - \dot{\phi}_l}{l} \end{bmatrix} = \begin{bmatrix} v \\ 0 \\ \omega \end{bmatrix} \xrightarrow{\text{转换到惯性系}} \begin{cases} \dot{x} = v \cos \theta \\ \dot{y} = v \sin \theta \\ \dot{\theta} = \omega \end{cases}$$

码盘读数为：

$$\begin{cases} \Delta s = \frac{r}{2}(\Delta \phi_R + \Delta \phi_L) \\ \Delta \theta = \frac{r}{2d}(\Delta \phi_R - \Delta \phi_L) \end{cases} \xrightarrow{\text{小时间变化}} \begin{cases} \Delta s = v_k T_s \\ \Delta \theta = \omega_k T_s \end{cases}$$

## 建模方法 11




图 8: 里程计建模方法

- 欧拉法

$$\begin{cases} x_{k+1} = x_k + v_k T_s \cos \theta_k \\ y_{k+1} = y_k + v_k T_s \sin \theta_k \\ \theta_{k+1} = \theta_k + \omega_k T_s \end{cases}$$

- RK2（二阶Runge-Kutta）法

$$\begin{cases} x_{k+1} = x_k + v_k T_s \cos(\theta_k + \frac{\omega_k T_s}{2}) \\ y_{k+1} = y_k + v_k T_s \sin(\theta_k + \frac{\omega_k T_s}{2}) \\ \theta_{k+1} = \theta_k + \omega_k T_s \end{cases}$$

- 解析积分法

$$\begin{cases} x_{k+1} = x_k + \frac{v_k}{\omega_k} (\sin \theta_{k+1} - \sin \theta_k) \\ y_{k+1} = y_k - \frac{v_k}{\omega_k} (\cos \theta_{k+1} - \cos \theta_k) \\ \theta_{k+1} = \theta_k + \omega_k T_s \end{cases} \xrightarrow{\omega_k=0} \begin{cases} x_{k+1} = x_k + v_k T_s \\ y_{k+1} = y_k \end{cases}$$

### 4.3.2 里程计误差

#### 误差来源

- 数值积分误差。
- 运动学参数误差：速度不恒定，半径误差。
- 打滑。

#### 误差传播（RK2法）

12

位姿更新为：

$$p' = f(x, y, \theta, \Delta\phi_R, \Delta\phi_L) = \begin{bmatrix} x \\ y \\ \theta \end{bmatrix} + \begin{bmatrix} \frac{r(\Delta\phi_R + \Delta\phi_L)}{2} \cos(\theta_k + \frac{r[\Delta\phi_R - \Delta\phi_L]}{4d}) \\ \frac{r(\Delta\phi_R + \Delta\phi_L)}{2} \sin(\theta_k + \frac{r[\Delta\phi_R - \Delta\phi_L]}{4d}) \\ \frac{r(\Delta\phi_R - \Delta\phi_L)}{2d} \end{bmatrix}$$

其中 $\Delta\phi_R, \Delta\phi_L$ 是控制输入量，有误差协方差矩阵迭代公式：

$$\sum_{p'} = \underbrace{\nabla_p f \cdot \sum_p \cdot \nabla_p f^T}_{\text{位姿}} + \underbrace{\nabla_{r|l} f \cdot \sum_{\Delta} \cdot \nabla_{r|l} f^T}_{\text{控制输入量}}$$

初始化姿态协方差矩阵 $\sum_{p'}$ （可零初始化），其更新量为：

$$\nabla_p f = \begin{bmatrix} \frac{\partial f}{\partial x} & \frac{\partial f}{\partial y} & \frac{\partial f}{\partial \theta} \end{bmatrix} = \begin{bmatrix} 1 & 0 & -\Delta s \sin(\theta_k + \frac{\Delta\theta}{2}) \\ 0 & 1 & \Delta s \cos(\theta_k + \frac{\Delta\theta}{2}) \\ 0 & 0 & 1 \end{bmatrix}$$

假设 $\Delta\phi_R, \Delta\phi_L$ 的误差相互独立，有控制输入量协方差矩阵：

$$\Sigma_{\Delta} = \text{covar}(\Delta\phi_R, \Delta\phi_L) = \begin{bmatrix} k_r \|\Delta\phi_R\| & 0 \\ 0 & k_l \|\Delta\phi_L\| \end{bmatrix}$$

其更新量为：

$$\nabla_{rl} f = \begin{bmatrix} \frac{\partial f}{\partial \Delta\phi_R} & \frac{\partial f}{\partial \Delta\phi_L} \end{bmatrix} = \begin{bmatrix} \frac{r}{2} \cos(\theta_k + \frac{\Delta\theta}{2}) - \frac{r}{4d} \Delta s \sin(\theta_k + \frac{\Delta\theta}{2}) & \frac{r}{2} \cos(\theta_k + \frac{\Delta\theta}{2}) + \frac{r}{4d} \Delta s \sin(\theta_k + \frac{\Delta\theta}{2}) \\ \frac{r}{2} \sin(\theta_k + \frac{\Delta\theta}{2}) + \frac{r}{4d} \Delta s \cos(\theta_k + \frac{\Delta\theta}{2}) & \frac{r}{2} \sin(\theta_k + \frac{\Delta\theta}{2}) - \frac{r}{4d} \Delta s \cos(\theta_k + \frac{\Delta\theta}{2}) \\ \frac{r}{2d} & -\frac{r}{2d} \end{bmatrix}$$

误差转化展示 原理见9.1。




图 9: 里程计误差转化展示

直线运动时误差方向与运动方向垂直，曲线运动时则不垂直。

## 4.4 激光传感器

- 组成：激光器，激光检测器，测量电路。
- 特点：无接触远距离测量，速度快，精度高，量程大，抗干扰能力强。
- 激光测距：到达时间法（Time of Flight, TOF）：时间精度 =  $\frac{\text{测量精度}}{c(3 \times 10^8)}$ 。
- 位移测量：对参考信号和测量信号进行相位测量。

## 5 机器人点云处理

### 5.1 直线提取

#### 5.1.1 最小二乘法 (Least Squares Method)

在求解拟合直线时，最小化拟合误差平方和，目标式为：

$$\min \sum_{i=1}^n d_i^2 = \min \sum_{i=1}^n [y_i - f(x_i)]^2$$

其中 $f(x) = ax + b$ 是拟合直线， $(x, y)$ 是待拟合的点坐标。

#### 求解方法

1. 求偏导：求目标式关于 $a, b$ 的偏导，得到如下极值条件：

$$\begin{cases} \frac{\partial \Pi}{\partial a} = 2 \sum_{i=1}^n [y_i - (a + bx_i)] = 0 \\ \frac{\partial \Pi}{\partial b} = 2 \sum_{i=1}^n x_i [y_i - (a + bx_i)] = 0 \end{cases}$$

2. 矩阵形式 <sup>13</sup>：将拟合直线 $f(x) = ax + b$ 增广为矩阵形式 $Y = X\beta$ ，在误差 $d = Y - X\beta$ 趋于0时，有 $Y = X\beta$ ，因此：

$$Y = X\beta \Rightarrow X^T Y = X^T X\beta \Rightarrow \beta = (X^T X)^{-1} X^T Y$$

#### 5.1.2 Split-and-Merge (分割与合并) <sup>14</sup>

1. 分裂 (Split)：以全集作为初始点集。对当前点集拟合直线（采用端点拟合），计算到最远点的距离，距离大于阈值则在该最远点处将点集分裂为两个子集，并对分裂后的两个子集进行迭代。
2. 合并 (Merge)：检查相邻线段是否满足合并要求（合并后是否有过远点），若满足要求，则合并并拟合新的直线。

#### 5.1.3 Line-Regression (线性回归)

1. 滑动拟合：选取窗口，在其内采用最小二乘法拟合直线，之后滑动窗口拟合新的直线。
2. 合并：检查相邻线段是否满足合并的角度和距离要求，满足则合并并拟合新的直线，直到所有线段不可再合并。

### 5.1.4 RANSAC (Random Sample Consensus, 随机抽样一致性算法) 15

- 外点 (outliers): 异常值。
  - 内点 (inliers): 符合模型的数据点。
1. 根据内点比例 $w$ 和找到一个完全由内点组成的样本的希望概率 $p$ 计算迭代次数:

$$k = \frac{\log(1-p)}{\log(1-w^2)}$$

2. 从所有数据点中随机选择最小数量 (直线2点, 平面3点) 的数据点子集, 确定唯一的模型参数。
3. 计算剩余数据点与该模型的误差, 小于设定阈值的为内点。
4. 重复迭代次数次采样, 选取包含最多内点的模型。

### 5.1.5 Hough-Transform (霍夫变换)

图像空间中的一个点对应Hough空间中的一条线。激光定位任务中, 常用极坐标 $\rho = x \cos \theta + y \sin \theta$ 表示。在定距下, 误差呈正态分布; 而在变距下, 误差增长与距离正相关。

1. 计算数据范围 (Hough空间参数分辨率), 并初始化累加器。
2. 遍历边缘点, 计算可能的参数组合, 并在对应位置进行投票。
3. 在累加器中寻找峰值 (可能不唯一), 获得相应Hough空间参数。
4. 转换回图像空间, 确定直线。

## 最小二乘直线拟合

点 $(\rho_i, \theta_i)$ 到拟合直线 $(r, \alpha)$ 的距离近似为 $d_i$ :

$$\rho_i \cos(\theta_i - \alpha) - r = d_i$$

使其加权平方和最小, 得到最优拟合直线。

误差传播为:

$$C_x = \begin{bmatrix} \text{diag}(\sigma_\rho^2) & 0 \\ 0 & \text{diag}(\sigma_\theta^2) \end{bmatrix}_{2n \times 2n} \quad F_{\rho\theta} = \begin{bmatrix} \frac{\partial \alpha}{\partial \rho_1} & \frac{\partial \alpha}{\partial \rho_2} & \cdots & \frac{\partial \alpha}{\partial \theta_{n-1}} & \frac{\partial \alpha}{\partial \theta_n} \\ \frac{\partial r}{\partial \rho_1} & \frac{\partial r}{\partial \rho_2} & \cdots & \frac{\partial r}{\partial \theta_{n-1}} & \frac{\partial r}{\partial \theta_n} \end{bmatrix}$$

$$C_{\alpha r} = F_{\rho\theta} C_x F_{\rho\theta}^T$$

### 5.1.6 性能对比

算法	复杂度	假阳性率FPR	精度	多直线检测	属性
Split-and-Merge	$n \log n$	低	低	适用	
Line-Regression	$nn_f$	低	低	适用	有序点云
RANSAC	$Snk$	高	高	需调整	容忍外点
Hough-Transform	$Snn_C + Sn_R n_C$	高	高	适用	

表 5: 直线特征提取算法性能对比

## 5.2 定位与匹配

### 5.2.1 基于SVD的定位算法 <sup>16</sup>

#### 条件与目标

在二维平面上，有基于世界坐标系的点云  $P = \{p_1, p_2, \dots, p_n\}$  和基于激光坐标系的点云  $Q = \{q_1, q_2, \dots, q_n\}$ ，它们按下标顺序匹配，求解刚体变换（旋转阵  $R$  和平移量  $t$ ）。

以误差平方加权和的形式建模，得到目标式：

$$(R, t) = \operatorname{argmin} \sum_{i=1}^n w_i \| (Rp_i + t) - q_i \|^2$$

其中  $w_i$  表示匹配点对  $(p_i, q_i)$  的权重，可取为距离的倒数  $w_i = \frac{1}{\sigma_i(\rho_i)}$ 。

#### 加权平均

为求极值，对目标式求关于  $t$  的偏导：

$$2t \left( \sum_{i=1}^n w_i \right) + 2R \left( \sum_{i=1}^n w_i p_i \right) - 2 \sum_{i=1}^n w_i q_i = 0 \xrightarrow[\sum_{i=1}^n w_i]{\text{等号两边同除}} t + R \frac{\left( \sum_{i=1}^n w_i p_i \right)}{\sum_{i=1}^n w_i} - \frac{\sum_{i=1}^n w_i q_i}{\sum_{i=1}^n w_i} = 0$$

取两个点云的加权中心点  $\hat{p} = \frac{\sum_{i=1}^n w_i p_i}{\sum_{i=1}^n w_i}$ ,  $\hat{q} = \frac{\sum_{i=1}^n w_i q_i}{\sum_{i=1}^n w_i}$ ，上式可化简为  $t = \hat{q} - R\hat{p}$ 。该式描述了平移量和旋转阵的关系，将其带回目标式，得到单变量最值问题：

$$R = \operatorname{argmin} \sum_{i=1}^n w_i \| R(p_i - \hat{p}) - (q_i - \hat{q}) \|^2$$

## 去中心化

取去中心化 $x_i = p_i - \hat{p}$ ,  $y_i = q_i - \hat{q}$ , 目标式可化简为:

$$R = \operatorname{argmin} \sum_{i=1}^n w_i \|Rx_i - y_i\|^2$$

将平方项变成矩阵相乘的形式:

$$\|Rx_i - y_i\|^2 = (Rx_i - y_i)^T (Rx_i - y_i) = x_i^T (R^T R) x_i - y_i^T R x_i - x_i^T R^T y_i + y_i^T y_i$$

- 旋转阵为标准正交阵,  $R^{-1} = R^T$ , 因此 $R^T R = E$ 。
- $x_i^T R^T y_i$ 是一个 $1 \times 1$ 标量, 转置后不变,  $x_i^T R^T y_i = y_i^T R x_i$ 。

所以:

$$\|Rx_i - y_i\|^2 = x_i^T x_i - 2y_i^T R x_i + y_i^T y_i$$

其中仅有负号项与 $R$ 相关, 其它项都是定值, 目标可改写为:

$$R = \operatorname{argmax} \sum_{i=1}^n w_i y_i^T R x_i$$

## SVD分解

将其写成对角阵的迹的形式:

$$\begin{aligned} \sum_{i=1}^n w_i y_i^T R x_i &= \operatorname{tr}(\operatorname{diag}(w_1 y_1^T R x_1, w_2 y_2^T R x_2, \dots, w_n y_n^T R x_n)) \\ &= \operatorname{tr}(\operatorname{diag}(w_1, w_2, \dots, w_n) \begin{bmatrix} y_1^T & y_2^T & \vdots & y_n^T \end{bmatrix}^T R \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix}) \\ &= \operatorname{tr}(W Y^T R X) \end{aligned}$$

因为矩阵的迹满足 $\operatorname{tr}(AB) = \operatorname{tr}(BA)$ , 所以 $\operatorname{tr}(W Y^T R X) = \operatorname{tr}(R X W Y^T)$ 。令 $S = X W Y^T$ , 基于SVD原理 (见附录9.2),  $S = U \Sigma V^T$ , 其中 $U, V$ 是单位正交阵,  $\Sigma$ 为对角阵。所以 $\operatorname{tr}(R X W Y^T) = \operatorname{tr}(R U \Sigma V^T) = \operatorname{tr}(\Sigma V^T R U)$ , 后三者都是单位正交阵, 它们的积 $M$ 也是单位正交阵。目标改写为:

$$R = \operatorname{argmax} \operatorname{tr}(\Sigma M)$$

**求解 $R$ 和 $t$**  由于单位正交阵的最大迹是在单位阵下取得的, 最大值条件为 $M = E$ , 即 $R = V U^T$ 。代回 $R$ 和 $t$ 的关系式, 可确定 $t$ 。

### 5.2.2 基于ICP (Iterative Closest Point, 迭代最近点) 的点云匹配算法 <sup>17</sup>

1. 条件与目标：求解二维平面上检测点云 $P = \{p_1, p_2, \dots, p_{N_p}\}$ 和目标点云 $X = \{x_1, x_2, \dots, x_{N_x}\}$ 的匹配。
2. 计算最近点集：采取采样方法获得目标点云，并采用点集匹配方法为检测点云数据点匹配最近的目标点云数据点。
  - 均匀采样。
  - 随机采样。
  - 基于特征的采样。
  - 法向量空间采样。
  - Closest point Matching (CMP)。
  - Normal Shooting Matching。
  - Point-to-Plane Matching。
  - Projection Matching。
3. 变换：使用基于SVD的定位算法求解齐次变换矩阵并应用于检测点云。
4. 目标函数计算：统计对齐误差，如果达到阈值则停止迭代，否则重复上述操作。

## 6 机器人定位

### 6.1 定位与导航

**导航** 不能碰障碍物，掌握目标的方向。

- 基于行为：如沿墙边前进。
- 基于地图：已知地图，需要定位。

#### 定位

- 问题
  - 全局定位：未知初始位置，根据地图进行定位。
  - 位置跟踪：已知初始位置，跟踪位置变化。
  - 绑架问题。
- 方法：基于机载传感器、基于额外传感器和路标、里程计。



- 分类（不确定度分布）：连续单峰（卡尔曼滤波）、连续多峰、离散多峰（粒子滤波）、拓扑。

## 6.2 贝叶斯定位

**原理** 新信息出现后的概率 = 概率 × 新信息带来的调整：

$$p(x|y) = \frac{p(y|x)p(x)}{p(y)}$$

**思想** 使用低精度传感器（如里程计）跟踪运动状态，不确定度不断提高，定期使用高精度传感器（如激光雷达），修正估计。

### 特点

- |   |   |
|---|---|
| <ul style="list-style-type: none"> <li>● 连续型           <ul style="list-style-type: none"> <li>– 精度受传感器数据限制。</li> <li>– 通常是单一假设位姿估计。</li> <li>– 对于单一假设发散时会丢失。</li> <li>– 表示紧凑，计算资源需求合理。</li> </ul> </li> </ul> | <ul style="list-style-type: none"> <li>● 离散型           <ul style="list-style-type: none"> <li>– 精度受离散化分辨率限制。</li> <li>– 通常是多假设位姿估计。</li> <li>– 发散时收敛到另一单元，永不丢失。</li> <li>– 需大量内存和计算资源。</li> </ul> </li> </ul> |
|---|---|

## 6.3 基于卡尔曼滤波的定位

### 6.3.1 卡尔曼滤波

**推导** 两次独立测量的概率均服从正态分布  $p_1(q) = N(\hat{q}_1, \sigma_1^2)$ ,  $p_2(q) = N(\hat{q}_2, \sigma_2^2)$ , 它们整合得到的最终分布也服从正态分布:

$$\begin{aligned}
 p(q) &= p_1(q) \cdot p_2(q) = \frac{1}{\sigma_1 \sqrt{2\pi}} \exp\left(-\frac{(q - \hat{q}_1)^2}{2\sigma_1^2}\right) \cdot \frac{1}{\sigma_2 \sqrt{2\pi}} \exp\left(-\frac{(q - \hat{q}_2)^2}{2\sigma_2^2}\right) \\
 &= \frac{1}{2\sigma_1 \sigma_2 \pi} \exp\left[-\frac{(q - \hat{q}_1)^2}{2\sigma_1^2} - \frac{(q - \hat{q}_2)^2}{2\sigma_2^2}\right] \\
 &= \frac{1}{2\sigma_1 \sigma_2 \pi} \exp\left\{-\frac{1}{2} \left[ \frac{q^2(\sigma_1^2 + \sigma_2^2) - 2q(\hat{q}_1 \sigma_2^2 + \hat{q}_2 \sigma_1^2) + (\hat{q}_1^2 \sigma_2^2 + \hat{q}_2^2 \sigma_1^2)}{\sigma_1^2 \sigma_2^2} \right]\right\} \\
 &= \frac{1}{2\sigma_1 \sigma_2 \pi} \exp\left\{-\frac{1}{2} \left[ \frac{q^2 - \frac{2q(\hat{q}_1 \sigma_2^2 + \hat{q}_2 \sigma_1^2)}{\sigma_1^2 + \sigma_2^2} + \frac{(\hat{q}_1^2 \sigma_2^2 + \hat{q}_2^2 \sigma_1^2)}{\sigma_1^2 + \sigma_2^2}}{\frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2}} \right]\right\} \\
 &= \underbrace{\frac{1}{2\sigma_1 \sigma_2 \pi} \exp\left[-\frac{1}{2} \frac{\frac{\hat{q}_1^2 \sigma_2^2 + \hat{q}_2^2 \sigma_1^2}{\sigma_1^2 + \sigma_2^2} - \left(\frac{\hat{q}_1 \sigma_2^2 + \hat{q}_2 \sigma_1^2}{\sigma_1^2 + \sigma_2^2}\right)^2}{\frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2}}\right]}_{\text{常数}} \underbrace{\exp\left[-\frac{1}{2} \frac{(q - \frac{\hat{q}_1 \sigma_2^2 + \hat{q}_2 \sigma_1^2}{\sigma_1^2 + \sigma_2^2})^2}{\frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2}}\right]}_{\text{正态分布}} \\
 &= N(\hat{q}, \sigma^2)
 \end{aligned}$$

有:

$$\begin{aligned}
 \hat{q} &= \underbrace{\frac{\hat{q}_1 \sigma_2^2 + \hat{q}_2 \sigma_1^2}{\sigma_1^2 + \sigma_2^2}}_{\text{方差小的项权重重大}} \Leftrightarrow \hat{q} = \hat{q}_1 + \underbrace{\frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} (\hat{q}_2 - \hat{q}_1)}_{\text{校正量}} \\
 \sigma^2 &= \frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2} \Leftrightarrow \sigma^2 = \underbrace{\sigma_1^2 - \frac{\sigma_1^4}{\sigma_1^2 + \sigma_2^2}}_{< \sigma_1^2, \sigma_2^2}
 \end{aligned}$$

以  $P = \sigma_1^2$ ,  $Q = \sigma_2^2$ ,  $R = \sigma^2$ , 记卡尔曼增益  $K = P(P + Q)^{-1}$  和创新协方差  $\Sigma_{IN} = P + Q$ :

$$\begin{aligned}
 \hat{q} &= \hat{q}_1 + P(P + Q)^{-1}(\hat{q}_2 - \hat{q}_1) = \hat{q}_1 + K(\hat{q}_2 - \hat{q}_1) \\
 R &= P - P(P + Q)^{-1}P = P - K \cdot \Sigma_{IN} \cdot K^T
 \end{aligned}$$

过程(推算)方程:  $x_k = Ax_{k-1} + Bu_{k-1} + w_{k-1}$

测量方程:  $z_k = Hx_k + v_k$

其中 $x_k \in \mathbb{R}^n$ 为系统状态， $z_k \in \mathbb{R}^m$ 为测量输出， $u_k \in \mathbb{R}^l$ 为系统输入。 $w_k \in \mathbb{R}^n$ 为过程噪声（Process Noise） $p(w) = N(0, Q)$ ， $v_k \in \mathbb{R}^m$ 为测量噪声（Measurement Noise，白噪声） $p(v) = N(0, R)$ 。

有先/后验估计 $\hat{x}_k^-$ ,  $\hat{x}_k$ ，先/后验估计误差 $e_k^- = x_k - \hat{x}_k^-$ ,  $e_k = x_k - \hat{x}_k$ ，先/后验估计方差 $P_k^- = E[e_k^- e_k^{-T}]$ ,  $P_k = E[e_k e_k^T]$ 。其中，优化目标是 $\arg\min_K P_k$ 。

先后验转化关系为：

$$\hat{x}_k = \hat{x}_k^- + \underbrace{K}_{\text{卡尔曼增益}} \underbrace{(z_k - H\hat{x}_k^-)}_{\text{新息}}$$

$P_k$ 可进行转化：

$$\begin{aligned} P_k &= E[e_k e_k^T] = E[(x_k - \hat{x}_k)(x_k - \hat{x}_k)^T] \text{ (误差展开)} \\ &= E\{[x_k - [\hat{x}_k^- + K(z_k - H\hat{x}_k^-)]]\{x_k - [\hat{x}_k^- + K(z_k - H\hat{x}_k^-)]\}^T\} \text{ (代入先后验转化关系)} \\ &= E\{[(x_k - \hat{x}_k^-) - K(Hx_k + v_k - H\hat{x}_k^-)][(x_k - \hat{x}_k^-) - K(Hx_k + v_k - H\hat{x}_k^-)]^T\} \text{ (代入测量方程)} \\ &= E\{[(I - KH)e_k^- - Kv_k][(I - KH)e_k^- - Kv_k]^T\} \text{ (误差重构)} \\ &= (I - KH) \underbrace{E[e_k^- e_k^{-T}]}_{P_k^-} (I - KH)^T + K \underbrace{E[v_k v_k^T]}_R K^T - K \underbrace{E[v_k e_k^{-T}]}_{\text{不相干, 0}} (I - KH)^T - (I - KH) \underbrace{E[e_k^- v_k^T]}_{\text{不相干, 0}} K^T \\ &= (I - KH)P_k^- (I - KH)^T + KRK^T \end{aligned}$$

令偏导为0：

$$\frac{\partial P_k}{\partial K} = -2P_k^- H^T + 2KHP_k^- H^T + 2KR = 0$$

有 $K = P_k^- H^T (HP_k^- H^T + R)^{-1}$ ，在方差趋于0时， $\lim_{R \rightarrow 0} K = H^{-1}$ ,  $\lim_{P_k^- \rightarrow 0} K = 0$ 。

## 步骤 18

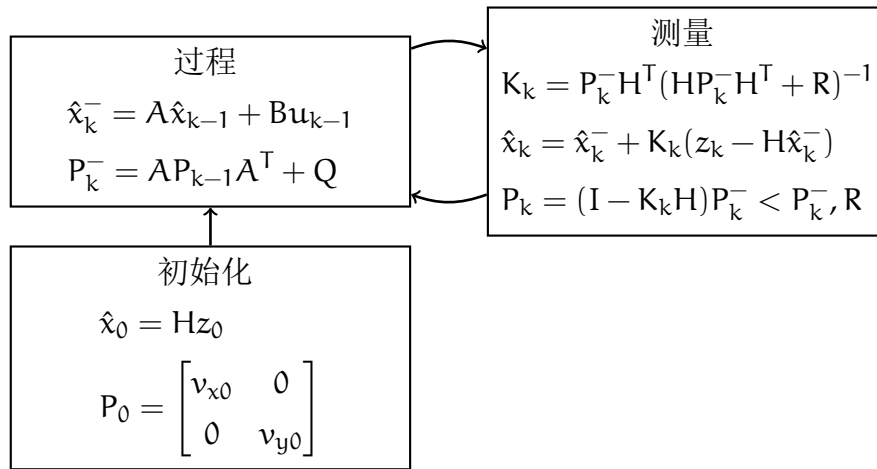


图 10: 卡尔曼滤波框图

6.3.2 基于卡尔曼滤波的定位算法 19

步骤 Prediction → Observation → Estimation




图 11: 基于卡尔曼滤波的定位算法示意图

- 1. 先验估计：预测模型，如里程计模型。
- 2. 先验估计误差：误差传导模型。
- 3. 观测：如激光定位，采用SVD确定位姿，采用ICP配准。
- 4. 观测误差：SVD匹配误差。
- 5. 基于观测的后验估计：卡尔曼滤波。

状态	状态转移A	测量	测量矩阵H	性能
$\begin{bmatrix} x_k \\ y_k \end{bmatrix}$	$\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$	$\begin{bmatrix} u_k \\ v_k \end{bmatrix}$	$\begin{bmatrix} u_k \\ v_k \end{bmatrix}$	动态误差大 静止误差小 适合缓慢移动
$\begin{bmatrix} x \\ y \\ \frac{dx}{dt} \\ \frac{dy}{dt} \end{bmatrix}$	$\begin{bmatrix} 1 & 0 & dt & 0 \\ 0 & 1 & 0 & dt \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$		$\begin{bmatrix} H_x & 0 & 0 & 0 \\ 0 & H_y & 0 & 0 \end{bmatrix}$ 未测量速度	动态误差小 静止误差大 低维估计高维

表 6: 卡尔曼滤波算法描述维度

描述维度

## 特点

- 严重依赖匹配精度，匹配失败则定位失败，且无法判断和恢复。
- 收敛速度受初始状态误差和协方差阵精度影响较大。
- 无法进行全局定位，无法应对绑架问题，只能位置跟踪。
- 不确定度需为单峰高斯分布。

## 6.4 蒙特卡洛定位

### 6.4.1 蒙特卡洛方法 (Monte Carlo Method)

不断抽样，逐渐逼近的方法。

## 特点

- 优点：通用。
- 缺点：收敛速度慢，不精确。

**分布函数拟合** 用样本（粒子）分布来处理各种分布。

- 已知概率分布求粒子分布：采样排除法，概率高的地方采样密集。
- 未知概率分布求粒子分布：重要性评估，迭代，根据预估分布（以均匀分布开始）洒粒子，再根据结果调整重要性评估（归一化）。

### 6.4.2 蒙特卡洛定位算法（粒子滤波算法，MCL） 20

多信息融合，提高真值处的重要性。

## 重要性采样

目标分布  $f_i = [p(x_i|z_1, z_2, z_3)]$ ，根据贝叶斯定理，有：

$$p(x_i|z_1, z_2, \dots, z_n) = \frac{\prod_k p(z_k|x_i)p(x_i)}{p(z_1, z_2, \dots, z_n)}$$

建议分布  $g_i = [p(x|z_i)]$ ，有：

$$p(x_i|z_i) = \frac{p(z_i|x_i)p(x_i)}{p(z_i)}$$

有重要性权重：

$$w_i = \frac{f_i}{g_i} = \frac{p(x_i|z_1, z_2, \dots, z_n)}{p(x_i|z_i)} = \frac{p(z_i) \prod_{k \neq i} p(z_k|x_i)}{p(z_1, z_2, \dots, z_n)}$$

令  $\eta = \frac{p(z_i)}{p(z_1, z_2, \dots, z_n)}$ ，则有  $w_i \propto \prod_{k \neq i} p(z_k|x_i)$ 。

**步骤** 在一次迭代 ( $X_{t-1} \rightarrow X_t$ ) 中，经历以下过程：

1. 预测：基于运动模型（建议分布）对粒子进行更新和采样：

$$x_t^{(i)} = f(x_{t-1}^{(i)}, u_t)$$

2. 校正：使用传感器模型计算粒子权重：

$$w_t^{(i)} = p(z_t|x_t^{(i)})$$

3. 重采样：根据归一化后的权重进行重采样（采用轮盘赌），权重越大的粒子被采样的概率越高。

**激光雷达观测误差模型**  $m$ 指地图。

- 误差

- 激光雷达测量误差  $p_{hit}(z_t|x_t, m)$ 。
- 没有检测到障碍物  $p_{max}(z_t|x_t, m)$ ：常值分布，返回激光雷达最大测距距离。

$$p_{max}(z_t|x_t, m) = \begin{cases} 1 & z_t^k = z_{max} \\ 0 & otherwise \end{cases}$$

- 随机错误  $p_{rand}(z_t|x_t, m)$ ：均匀分布，返回错误的距离值。

$$p_{rand}(z_t|x_t, m) = \begin{cases} \frac{1}{z_{max}} & 0 \leq z_t^k \leq z_{max} \\ 0 & otherwise \end{cases}$$

- 激光雷达观测误差模型 $p(z_t|x_t, m)$ ：上述误差的线性组合。

$$p(z_t|x_t, m) = \alpha_{\text{hit}}p_{\text{hit}} + \alpha_{\text{max}}p_{\text{max}} + \alpha_{\text{rand}}p_{\text{rand}} \quad \alpha_{\text{hit}} + \alpha_{\text{max}} + \alpha_{\text{rand}} = 1$$

- 物理模型： $p_{\text{hit}}(z_t|x_t, m)$ 包含随机噪声，一般为高斯分布。

$$p_{\text{hit}}(z_t|x_t, m) = \begin{cases} N(z_t^k, \sigma_{\text{hit}}^2) & 0 \leq z_t^k \leq z_{\text{max}} \\ 0 & \text{otherwise} \end{cases}$$

- 可能域 (likelihood)： $p_{\text{hit}}(z_t|x_t, m)$ ，将激光束投影到地图中，以距投影最近的点的距离为均值，激光测距偏差为方差。
  - 优点：在线计算量小，平滑性好，收敛性强，更符合实际情况。
  - 缺点：没有明确的物理意义，仅适用于相对静态的环境（如有路标的工厂）。

## 特点

- 优点：计算简单，可解决大范围全局定位问题，适用于多种分布。
- 缺点：粒子数过大时占用内存大，计算效率低；大地图下，只用少量粒子可能发散；无法应对绑架问题。

### 6.4.3 自适应蒙特卡洛定位算法 (AMCL) 21

**改进** 引入短、长期指数滤波器衰减率 $\alpha_{\text{slow}} \ll \alpha_{\text{fast}}$ ，计算短、长期重要性指数似然评价估计 $w_{\text{slow}}, w_{\text{fast}}$ ，二者计算公式格式一致，正常时 $w_{\text{slow}} < w_{\text{fast}}$ 。

## 解决问题

- 绑架问题：发生绑架问题时， $w_{\text{avg}}$ 会突然下降，导致 $w_{\text{slow}} > w_{\text{fast}}$ ，将按照概率 $\max(0, 1 - \frac{w_{\text{fast}}}{w_{\text{slow}}})$ 向粒子集中注入随机粒子。
- 粒子数问题：使用KLD (Kullback-Leibler Divergence, 库尔贝克-莱布勒散度，计算概率分布间差异) 采样，在趋于收敛的过程中减少粒子。

**算法** 其中标红部分是AMCL相较MCL的改进。

### 算法 1: AMCL

- 1: 参数:  $\alpha_{\text{slow}}, \alpha_{\text{fast}}$
- 2: 初始化: 初始化  $\bar{X}_t = X_t$  为空, 初始化  $w_{\text{slow}}, w_{\text{fast}}$
- 3: 对于  $m = 1, \dots, M$  执行
- 4:      $x_t^{[m]} = f(u_t, x_{t-1}^{[m]})$
- 5:      $w_t^{[m]} = p(z_t, x_t^{[m]}, m)$
- 6:      $\bar{X}_t = \bar{X}_t + \langle x_t^{[m]}, w_t^{[m]} \rangle$
- 7:      $w_{\text{avg}} = w_{\text{avg}} + \frac{1}{M} w_t^{[m]}$  ▷ 平均权重
- 8:      $w_{\text{slow}} = w_{\text{slow}} + \alpha_{\text{slow}}(w_{\text{avg}} - w_{\text{slow}})$  ▷ 慢速权重
- 9:      $w_{\text{fast}} = w_{\text{fast}} + \alpha_{\text{fast}}(w_{\text{avg}} - w_{\text{fast}})$  ▷ 快速权重
- 10: 对于  $m = 1, \dots, M$  执行
- 11:     以概率  $\max(0, 1 - \frac{w_{\text{fast}}}{w_{\text{slow}}})$  向  $X_t$  添加随机姿态 ▷ 应对绑架问题
- 12:     否则, 从  $\bar{X}_t$  中按概率  $w_t^{[m]}$  采样  $x_t^{[m]}$ , 并将其添加到  $X_t$  ▷ 重采样
- 13: 返回  $X_t$

## 7 机器人建图

### 7.1 地图

#### 功能

- 支持机器人进行定位、导航、规划。
- 容易加入新的信息进行更新。
- 便于计算机储存和处理。

#### 表示法

- 点云地图
  - 优点: 可以完全表示环境三维信息, 不需要预定义尺寸。
  - 缺点: 存储要求高, 存在盲区和空洞, 需要处理来判断占用和联通状态, 不具有通用性 (不同机器人无法共用)。



- 栅格地图：以允许误差大小确定栅格大小，用0-1的值表示栅格被占用的概率（不同激光数据中占用的概率）。

#### – 计算

- \* 概率：  $p(m_i|s_n) = 1 - E_r E_\alpha$ ，其中：

$$E_r = 1 - k_r \left( \frac{2(\rho_i - r_i)}{\Delta r} \right)^2, E_\alpha = 1 - k_\alpha \left( \frac{2(\theta_i - \alpha)}{\Delta \alpha} \right)^2$$

- \* 几率：几率  $l = \frac{\text{概率} p}{1 - \text{概率} p}$ ，几率与概率非线性正相关。

利用贝叶斯公式得到每次测量（相互独立）的递推关系：

$$\begin{aligned} p(m_i|s_1, s_2, \dots, s_n) &= \frac{p(s_n|m_i, s_1, s_2, \dots, s_{n-1})p(m_i|s_1, s_2, \dots, s_{n-1})}{p(s_n|s_1, s_2, \dots, s_{n-1})} \\ &= \frac{p(s_n|m_i)p(m_i|s_1, s_2, \dots, s_{n-1})}{p(s_n)} \\ &= \frac{p(m_i|s_n)p(s_n)p(m_i|s_1, s_2, \dots, s_{n-1})}{p(m_i)p(s_n)} \\ &= \frac{p(m_i|s_n)p(m_i|s_1, s_2, \dots, s_{n-1})}{p(m_i)} \end{aligned}$$

有对数几率更新公式：

$$\begin{aligned} l_{i,n} &= \log \frac{p(m_i|s_1, s_2, \dots, s_n)}{p(\bar{m}_i|s_1, s_2, \dots, s_n)} = \log \frac{p(m_i|s_n)p(\bar{m}_i)p(m_i|s_1, s_2, \dots, s_{n-1})}{p(\bar{m}_i|s_n)p(m_i)p(\bar{m}_i|s_1, s_2, \dots, s_{n-1})} \\ &= \log \frac{p(m_i|s_n)}{p(\bar{m}_i|s_n)} + \underbrace{\log \frac{p(\bar{m}_i)}{p(m_i)}}_{l_0 \text{ 与测量无关}} + \log \frac{p(m_i|s_1, s_2, \dots, s_{n-1})}{p(\bar{m}_i|s_1, s_2, \dots, s_{n-1})} \\ &= \log \frac{p(m_i|s_n)}{p(\bar{m}_i|s_n)} + \underbrace{l_0}_{\text{占用情况未知时, 令 } p(m_i)=0.5, l_0=0} + l_{i,n-1} \end{aligned}$$

#### – 特点

- \* 优点：可以详细描述环境信息，易于定位和路径规划，不需要预定义尺寸。
- \* 缺点：存储要求高，存在盲区和空洞，需要处理来判断占用和联通状态（点占用不够），不具有通用性（不同机器人无法共用）。

#### – 拓展

- \* 2.5维占用栅格地图（扩展高度图）：为每个栅格附加高度信息（障碍物最高高度）。

- \* 3维占用栅格地图（Voxel Map，体素地图）：将空间分解为正方体，判断占用情况。
- \* 多分辨率地图：障碍质密处栅格小，无障碍处栅格大，空间占用率高，计算复杂度高，存储存在稀疏特征。
- 特征（语义）地图：连续多边形地图，空间占用效率高，定位精度高。
- 拓扑地图：节点和连线的拓扑结构图，便于导航和路径规划，难以精确定位。

## 7.2 SLAM（Simultaneous Localization and Mapping，同步定位与建图）

### 问题描述

- 定位（Localization）：根据观测序列、运动序列和地图，确定位姿。误差源于全局定位的初始误差和局部定位的观测误差。

$$E[X^t | Z^t, U^{t-1}, m]$$

- 建图（Mapping）：根据观测序列和位姿，构建地图。误差源于观测噪声。

$$E[m | Z^t, X^t]$$

- SLAM：根据观测序列、运动序列，确定位姿并构建地图。

$$E[X^t, m | Z^t, U^{t-1}]$$

**SLAM关键** 使用闭环检测进行数据关联，降低估计的不确定度。错误的匹配会使算法发散。

### 分类

- 基于滤波：EKF-SLAM（卡尔曼滤波）、FastSLAM（粒子滤波，GMAPPING包）。
- 基于优化：图优化（g2o包），主流。

## 7.3 基于滤波的SLAM算法

### 7.3.1 EKF-SLAM（扩展卡尔曼滤波SLAM） 22

第一个SLAM算法，面向特征地图，采用maximum likelihood进行数据关联。

**状态** 机器人位姿为三维 $X_R = [x \ y \ \theta]^T$ ，地图特征为二维 $M_i = [x_i \ y_i]^T$ 。

$$x_t = \begin{bmatrix} X_R \\ M_1 \\ M_2 \\ \vdots \\ M_n \end{bmatrix}_{(3+2n) \times 1} \quad \Sigma_t = \begin{bmatrix} \Sigma_{X_R} & \Sigma_{X_R m_1} & \Sigma_{X_R m_2} & \cdots & \Sigma_{X_R m_n} \\ \Sigma_{m_1 X_R} & \Sigma_{m_1} & \Sigma_{m_1 m_2} & \cdots & \Sigma_{m_1 m_n} \\ \Sigma_{m_2 X_R} & \Sigma_{m_2 m_1} & \Sigma_{m_2} & \cdots & \Sigma_{m_2 m_n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \Sigma_{m_n X_R} & \Sigma_{m_n m_1} & \Sigma_{m_n m_2} & \cdots & \Sigma_{m_n} \end{bmatrix}_{(3+2n) \times (3+2n)}$$

高斯协方差矩阵表征了高度互相关性。

### 步骤

1. 初始状态： $X_0 = 0, \Sigma_0 = \text{diag}(\infty)$ 。
2. 基于运动模型进行状态估计：地图保持不变，与其相关项为0。

$$\bar{X}_t = f'(X_{t-1}, U_{t-1})$$

$$\bar{\Sigma}_{X_R} = \nabla f \cdot \Sigma_{R_{t-1}} \cdot \nabla f^T + R_t, \quad \bar{\Sigma}_t = \nabla f' \cdot \Sigma_{R_{t-1}} \cdot \nabla f'^T + F_x^T R_t F_x, \quad \nabla f' = \begin{bmatrix} \nabla f & 0 \\ 0 & I \end{bmatrix}$$

3. 基于观测模型进行预估观测：每个路标观测独立，交叉项为0。

$$\hat{Z}_t = \begin{bmatrix} Z_{1t} \\ Z_{2t} \\ \vdots \\ Z_{nt} \end{bmatrix}, \quad Q_t = \begin{bmatrix} Q_{1t} & 0 & \cdots & 0 \\ 0 & Q_{2t} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & Q_{nt} \end{bmatrix}$$

4. 建立状态估计和预估观测的数据关联。

$$K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + Q_t)^{-1}$$

5. 状态更新。

$$X_t = \bar{X}_t + K_t [\hat{Z}_t - h(\bar{X}_t)], \quad \Sigma_t = [I - K_t H_t] \bar{\Sigma}_t$$

6. 获得实际观测：全局地图 = 全局观测位置 + 机器人测量数据。

机器人系的激光观测数据 $z_t^i = [r_t^i, \phi_t^i]$ ，投影到世界坐标系：

$$\begin{pmatrix} \bar{x}_m \\ \bar{y}_m \end{pmatrix} = \begin{pmatrix} \bar{x}_R \\ \bar{y}_R \end{pmatrix} + \begin{pmatrix} r_t^i \cos(\phi_t^i + \bar{\theta}_R) \\ r_t^i \sin(\phi_t^i + \bar{\theta}_R) \end{pmatrix}$$

转换得到：

$$\delta = \begin{pmatrix} \delta_x \\ \delta_y \end{pmatrix} = \begin{pmatrix} \bar{x}_m - \bar{x}_R \\ \bar{y}_m - \bar{y}_R \end{pmatrix}, \quad q = \delta^T \delta, \quad \hat{z}_t^i = \begin{pmatrix} \sqrt{q} \\ \text{atan2}(\delta_y, \delta_x) - \bar{\theta}_R \end{pmatrix}$$

有单路标雅可比：

$$\begin{aligned} H_i^j &= {}^{\text{low}} H_i^j F_{x,j} \\ &= \frac{1}{q} \begin{pmatrix} -\sqrt{q}\delta_x & -\sqrt{q}\delta_y & 0 & \sqrt{q}\delta_x & \sqrt{q}\delta_y \\ \delta_y & -\delta_x & -q & -\delta_y & \delta_x \end{pmatrix} \begin{pmatrix} I_3 & 0_{2j-2} & 0 & 0_{2N-2j} \\ 0 & 0 & I_2 & 0 \end{pmatrix} \end{aligned}$$

7. 在地图中加入新的路标：新路标与原路标不独立，因为前者由不确定度决定，而不确定度有后者计算。

$$\begin{aligned} m_{n+1} &= f(X_R, Z_{n+1}) \\ \nabla f_R &= \frac{\partial f(X_R, Z_{n+1})}{\partial X_R}, \quad \nabla f_Z = \frac{\partial f(X_R, Z_{n+1})}{\partial Z_{n+1}} \\ \Sigma_{m_{n+1}} &= \nabla f_R \cdot \Sigma_{X_R} \cdot \nabla f_R^T + \nabla f_Z \cdot Q_{Z_{n+1}} \cdot \nabla f_Z^T \\ \Sigma_{m_{n+1}m_i} &= \nabla f_R \cdot \Sigma_{X_R m_i} \\ \Sigma_{m_{n+1}X_R} &= \nabla f_R \cdot \Sigma_{X_R} \end{aligned}$$

得到新的状态（标红部分为扩充内容）：

$$X_t = \begin{bmatrix} X_R \\ M_1 \\ M_2 \\ \vdots \\ M_n \\ \textcolor{red}{M_{n+1}} \end{bmatrix}, \quad \Sigma_t = \begin{bmatrix} \Sigma_{X_R} & \Sigma_{X_R m_1} & \cdots & \Sigma_{X_R m_n} & \textcolor{red}{\Sigma_{X_R m_{n+1}}} \\ \Sigma_{m_1 X_R} & \Sigma_{m_1} & \cdots & \Sigma_{m_1 m_n} & \textcolor{red}{\Sigma_{m_1 m_{n+1}}} \\ \Sigma_{m_2 X_R} & \Sigma_{m_2 m_1} & \cdots & \Sigma_{m_2 m_n} & \textcolor{red}{\Sigma_{m_2 m_{n+1}}} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \Sigma_{m_n X_R} & \Sigma_{m_n m_1} & \cdots & \Sigma_{m_n} & \textcolor{red}{\Sigma_{m_n m_{n+1}}} \\ \textcolor{red}{\Sigma_{m_{n+1} X_R}} & \textcolor{red}{\Sigma_{m_{n+1} m_1}} & \cdots & \textcolor{red}{\Sigma_{m_{n+1} m_n}} & \textcolor{red}{\Sigma_{m_{n+1}}} \end{bmatrix}$$

8. 重复2-7步。

## 特点

- 计算复杂度高。
- 要求高斯分布，只能处理单峰假设。
- 依赖数据关联正确性。
- 仅适用于有全连接人工路标的点云地图或特征地图，无法使用栅格地图。

### 7.3.2 FastSLAM (粒子滤波SLAM) 23

集成粒子滤波器与EKF，使用粒子分布表示位姿。

**粒子降维** 每个粒子相当于对机器人路径的一个假设，构建独立的地图，协方差矩阵只有对角线。

$$\mathbf{x} = (\underbrace{\mathbf{x}_1, \dots, \mathbf{x}_t}_{3t, \text{撒粒子获得}}, \underbrace{\mathbf{l}_{1,x}, \mathbf{l}_{1,y}, \dots, \mathbf{l}_{N,x}, \mathbf{l}_{N,y}}_{2N, \text{计算获得}})^T$$

基于饶布莱克维尔定理进行因式分解：

$$\begin{aligned} p(\underbrace{\mathbf{x}_{0:t}, \mathbf{l}_{1:M}}_{\text{地图(路标)}} | \mathbf{z}_{1:t}, \mathbf{u}_{1:t}) &= \underbrace{p(\mathbf{x}_{0:t} | \mathbf{z}_{1:t}, \mathbf{u}_{1:t})}_{\text{根据观测定位}} \underbrace{p(\mathbf{l}_{1:M} | \mathbf{x}_{0:t}, \mathbf{z}_{1:t}, \mathbf{u}_{1:t})}_{\text{根据观测建图}} \\ &= \underbrace{p(\mathbf{x}_{0:t} | \mathbf{z}_{1:t}, \mathbf{u}_{1:t})}_{\text{粒子滤波}} \prod_{i=1}^M \underbrace{p(\mathbf{l}_i | \mathbf{x}_{0:t}, \mathbf{z}_{1:t}, \mathbf{u}_{1:t})}_{\text{M个独立2维EKF}} \end{aligned}$$

其中粒子滤波部分不需要修正过去位姿信息，只需要维护当前位姿。

#### 步骤

1. 运动更新。
2. 计算新特征的EKF。
3. 地图更新。
4. 基于观测计算权重：仅与当前观测相关。

$$\begin{aligned} w^{[k]} &= \frac{\overbrace{p(\mathbf{x}_{1:t}^{[k]} | \mathbf{z}_{1:t}, \mathbf{u}_{1:t})}^{\text{目标分布}}}{\underbrace{p(\mathbf{x}_{1:t}^{[k]} | \mathbf{z}_{1:t-1}, \mathbf{u}_{1:t})}_{\text{建议分布}}} \\ &= \frac{\eta p(\mathbf{z}_t | \mathbf{x}_{1:t}^{[k]}, \mathbf{z}_{1:t-1}) p(\mathbf{x}_t^{[k]} | \mathbf{x}_{t-1}, \mathbf{u}_t) p(\mathbf{x}_{1:t-1}^{[k]} | \mathbf{z}_{1:t-1}, \mathbf{u}_{1:t-1})}{p(\mathbf{x}_t^{[k]} | \mathbf{x}_{t-1}, \mathbf{u}_t) p(\mathbf{x}_{1:t-1}^{[k]} | \mathbf{z}_{1:t-1}, \mathbf{u}_{1:t-1})} \\ &= \eta p(\mathbf{z}_t | \mathbf{x}_{1:t}^{[k]}, \mathbf{z}_{1:t-1}) \end{aligned}$$

5. 插入新特征。
6. 基于权重重采样。

**数据关联** 计算观测特征和地图特征的匹配概率，准的粒子概率高，不会因关联错误而全盘错误。

- 选择概率大的进行匹配。
- 按照概率进行随机匹配。

## 特点

- 降维高效。
- 随机采样使数据关联更鲁棒，利用多假设分析忽略位姿误差。
- 粒子数量选取：尽量多，过多可能占用过大内存，过少可能导致错误。

## 7.4 基于优化的SLAM算法

图优化SLAM：位姿通过约束相互连接，表征不确定性，寻求最优的节点构型使约束误差最小。

### 构建图（前端）

- 节点（Node）：机器人位姿，包含位姿 $x_{1:n}(x, y, \theta)$ 、特征或路标 $m_{1:k}(x, y)$ 信息。
  - 定位（Pose）： $x^T = (x_1^T, x_2^T, \dots, x_n^T) \in \mathbb{R}^{3n}$ 。
  - SLAM（Pose feature）： $x^T = (x_1^T, x_2^T, \dots, x_n^T, m_1^T, m_2^T, \dots, m_k^T) \in \mathbb{R}^{3n+2K}$ 。
- 边（Edge）：位姿间的空间约束，齐次坐标。
  - 里程计测量 $(X_i^{-1}X_{i+1})$ 和观测 $(X_i^{-1}X_j)$ 。
  - 信息矩阵：节点间空间约束的不确定性，优化的权重。协方差的逆，值越大相关性越高，越应重视。

### 图优化（后端）

- 定位： $e_{ij}(x_i, x_j) = t_2 v[z_{ij}^{-1}(x_i^{-1}x_j)] \xrightarrow{e_{ij}(x_i, x_j)=0} z_{ij} = (x_i^{-1}x_{i+1})$ 。
- SLAM： $e_{ij}(z_i, x_j) = \hat{z}_{ij} - z_{ij} = R_j^T(z_i - t_j) - z_{ij} \xrightarrow{e_{ij}(x_i, x_j)=0} z_{ij} = R_i^T(z_i - t_j)$ 。

## 例题 24




图 12: 图优化例题

1. 定位：起点在o处，向前移动到达远点，编码器测得位移1m，向后移动回到起点（闭环检测），编码器测得位移0.8米。

有目标函数：

$$c = \sum_{i=1}^4 f_i^2 = (x_0 - 0)^2 + (x_1 - x_0 - 1)^2 + [x_2 - x_1 - (-0.8)]^2 + (x_2 - x_0 - 0)^2$$

求偏导的得到方程组，解得：

$$\begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 3 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}^{-1} \begin{bmatrix} -1.0 \\ 1.8 \\ -0.8 \end{bmatrix} = \begin{bmatrix} 0 \\ 0.93 \\ 0.07 \end{bmatrix}$$

2. SLAM：起点在o处，观测到前方2m处有路标。向前移动到路标前0.8m处，编码器测得位移1m。

有目标函数：

$$c = \sum_{i=1}^4 f_i^2 = (x_0 - 0)^2 + (x_1 - x_0 - 1)^2 + (l_0 - x_0 - 2)^2 + (l_0 - x_1 - 0.8)^2$$

求偏导的得到方程组，解得：

$$\begin{bmatrix} x_0 \\ x_1 \\ l_0 \end{bmatrix} = \begin{bmatrix} 3 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}^{-1} \begin{bmatrix} -3.0 \\ 0.2 \\ 2.8 \end{bmatrix} = \begin{bmatrix} 0 \\ 1.07 \\ 1.93 \end{bmatrix}$$

优化求解 略

## 特点

- 仅将实际发生关联的约束构建连接并进行优化，且不是每次观测都需要更新（多分辨率），效率高。
- 优化思想而非概率思想，易理解和计算。

## 7.5 LOAM

基于激光和里程计。

- 运动畸变矫正：点云时间戳对齐，利用IMU信息（无IMU时假设匀速）。
- 特征点提取：平面点、边缘点。
- 双odometer：高频低精度和低频高精度结合。

# 8 机器人运动规划

## 8.1 运动规划（Motion Planning）

### 需求

- 安全性：规避障碍物。
- 可达性：从起点到终点的连通域。
- 光滑性：平稳舒适地运行。
- 可执行性：动力学约束和执行单元的性能约束。

### 分层规划

- 路径规划：只考虑几何约束，不考虑机器人和执行器约束。
  - 基于图搜索：算法完备，有限时间内返回解或返回无解。
  - 基于采样：概率完备。



- 轨迹规划：在给定路径上考虑机器人和执行器约束，生成随时间变化的运动序列。
  - 在线。
  - 离线

## 8.2 基于图搜索的路径规划

### 8.2.1 静态路径规划

#### 图的构建

- 可视图（visibility graph）：连线障碍物顶点和起点终点，找最短路径。可实现无碰撞最短路径距离规划，但太靠近障碍物。
- 维诺图（Voronoi graph）：路径距周围两个最近障碍物等距（ $L_1/L_2$ ）。最大化与障碍物的距离，安全但较长。
- Bug算法图：起点和重点连线，在障碍物处沿边缘行走，更新起点迭代。
- 精确单元分解地图。
- 栅格地图：关联格间无障碍。
- 拓扑地图。
- 搜索树。

#### 算法 25

算法	原理	完备性	最优性	补充
深度优先 (DFS)	分支遍历	完备	不最优	无方向性, 效率低下
宽/广度优先 (BFS, 泛洪搜索)	层次遍历	完备	不最优	无方向性, 效率低下
Dijkstra	计算节点到起点的代价, 优先遍历队列中代价最小的节点	完备	最优	地图信息利用不充分
A*	路径评价由移动开销G(n)和启发函数代价估计H(n)组合得到	完备	最优 (需满足可采纳性和一致性)	高效, 多解, 不一定平滑

表 7: 图搜索算法对比

启发函数:

- 可选: 曼哈顿距离、欧几里得距离、切比雪夫距离。
- 可采纳性: 低估代价。
- 一致性: 符合三角不等式。
- 选取优劣是算法效率的重要因素。

算法补充

- 权重A\*: 为启发函数添加权重 $\epsilon \geq 1$ , 限制扩展节点, 提高效率, 但不满足可采纳性, 只能得到局部最优。
- ARA\* (任意时间法+权重A\*): 快速得到次优, 再优化。

8.2.2 动态路径规划

动态环境特点

- 运行过程中地图可能改变, 有动态障碍物。

- 一般性环境，更符合实际。
- 需降低复杂度，提高实时性。

## 算法

- D\*（动态A\*）：由目标点向当前位置Dijkstra，利用变化前的地图信息进行动态规划。
- Focused D\*：将D\*的Dijkstra改为A\*。
- LPA\*：增量式搜索。
- D\*-Lite：LPA\*的动态形式。
- AD\*：结合ARA\*和D\*-Lite。

## 8.3 基于采样的路径规划

### 概述

- 采样：在障碍物处密集采样。
- 距离评估。
- 碰撞检测：凸障碍已比较完善，非凸障碍尚未完善。

### PRM（概率路图） 略

### RRT（快速探索随机树）

- RRT：迭代撒点，选择离目标近的点，按照这个方向步进（不一定到达），更新起点；最后到达终点附近，无法准确到达重点。完备而高效，但是只能得到可行解而非最优解。
- RRT\*：在路径的大圈中进行局部优化，重构节点关系，使局部最优。
- Informed RRT\*：在起点终点连线为主轴的椭圆中进行优化。

## 8.4 面向碰撞的局部路径规划

- DWA (Dynamic Window Approach): 评价函数对方向角、空隙、速度进行加权。计算复杂度低, 但可能得不到全局最优。
- TEB (Timed Elastic Band): 连接起点终点为可变形路径, 将约束视作引起形变的外力。

## 8.5 路径平滑

- 约束: 初始、终止状态约束。曲线光滑。
- 曲线形态: 圆弧、贝塞尔曲线。

## 8.6 轨迹规划

- 目标: 在执行器约束下, 沿给定光滑曲线的可执行的运动命令序列。
- 约束: 初始、终止状态约束, 执行器约束, 运动学约束。

# 9 附录

## 9.1 误差转化展示

将误差传播协方差矩阵 $\Sigma_p$ 转化成椭圆展示。

**计算** 取 $\Sigma_p$ 左上二阶子阵 $\Sigma_{p_{xy}} = \begin{bmatrix} \sigma_{xx} & \sigma_{xy} \\ \sigma_{xy} & \sigma_{yy} \end{bmatrix}$ , 计算特征值 $\lambda_1, \lambda_2$ 和特征向量 $\vec{p}_1, \vec{p}_2$ , 其分别表示长短轴的大小和方向, 圆心是 $(x_k, y_k)$  (直接对 $\Sigma_p$ 求取特征根和特征向量, 再取前两个, 结果与其不同)。

## 意义

- 长短轴表示误差在不同方向上的大小, 可通过开根号、乘系数等方法调节。

- 方向角表示误差传播的主要方向，体现了误差传播的各向异性。
- 椭圆大小反映了系统的误差范围，可按置信度缩放。

返回[里程计12](#)。

## 9.2 奇异值分解 (Singular Value Decomposition, SVD)

根据  $A_{m \times n}$  计算  $(A^T A)_{n \times n}$  和  $(A A^T)_{m \times m}$  两个对称矩阵，求二者的特征值和特征向量：

$$A^T A v_i = \lambda_i v_i, i = 1, 2, \dots, n \quad A A^T u_i = \mu_i u_i, i = 1, 2, \dots, m$$

其中， $\lambda_i, \mu_i$  是特征值， $v_i, u_i$  是其对应的特征向量，分别组成  $V = [v_1, v_2, \dots, v_n]$  和  $U = [u_1, u_2, \dots, u_m]$ 。

奇异值  $\sigma_i$  是  $\lambda_i, \mu_i$  的平方根，将其按降序排列，并构造对角矩阵  $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$ ，得到SVD分解  $A = U \Sigma V^T$ 。

返回[里程计5.2.1](#)。